SciResearch-Bench-Lite：科学计算自主研究基准设计与实验报告

课程作业最终报告 · 2026 年 10 月 25 日
研究领域：科学计算；提交形式：个人 GitHub 仓库。
提交仓库 · 阅读打印版 PDF · 离线阅读版 HTML · 完整材料与 Release

摘要与阅读说明

本项目关心一个具体问题：**AI 能否在有限时间和工具预算内，把科研任务转化为可运行的方法，并利用实验反馈改进结果？** 为此，在科学计算领域实现了三条任务：从温度观测恢复初始温度分布（Heat）、从带噪运动轨迹识别动力学方程（ODE）、在保证解正确的前提下加快稀疏方程求解（Poisson）。三条任务共生成 90 个合成实例，配置了 11 种作者基线，并由独立程序验证候选代码的输出。

实验包括两个分别统计的批次：原批次关闭 thinking；对照批次启用 thinking，并把 effort 设为 max。每批均包含 15 个研究会话，每会话最多 20 万输出 token、30 分钟和 20 次公开评估。原批次 9/15 有提交、6/15 达到成功条件；对照批次 15/15 有提交、14/15 取得有效且成功的最终成绩。剩余 Poisson G2 已通过数值检查，但正式计时窗口不合格，正式分数留空；其独立补测的原始耗时比为 **2.488×，仅作诊断**。

这些结果说明，本项目已形成“任务—数据—Agent 实验—可信提交—独立评分—日志分析”的可运行闭环。对照条件下提交率和多数任务成绩提高，但中途执行器修复、重复使用同一隐藏集、先后运行及小样本等因素，使我们不能把差异单独归因于 thinking，也不能据此宣称实现了真正的递归自我改进。

读表约定： 分数保留三位小数；`0` 是按规则得到的零分，`—` 是没有有效成绩，两者不同。`reward=1` 表示满足该任务全部成功条件，`reward=0` 表示有效评测下未成功。主表按 **Heat → ODE → Poisson、G1 → G2 → G3、r1 → r2 → r3** 排列，实际执行序号另列。完整精度和来源哈希见整理后的数据。

1. 背景与研究目标

普通问答往往只检查最终答案；科研工作还要求选择方法、实现代码、设计实验、识别失败并修改方案。一个程序能运行，不一定得到了正确科学结果；一次公开测试表现好，也不一定能推广到新的测试样本。因此，Auto Research Benchmark 需要同时评价研究过程与最终产物。

本报告采用以下工作定义：Auto Research 指让 Agent 自主完成方法选择、实验和改进；AI Scientist 的范围可以进一步包括提出想法、文献分析、写作与评审；Research Agent 是执行这些工作流的工具使用系统。RSI（Recursive Self-Improvement，递归自我改进）则要求系统修改自身的策略、工具或代码，并验证改进能作用于后续任务。**本项目测量的是 Agent 对当前求解器的研究与改进，没有把模型或 Agent 自身作为优化对象。**

选择科学计算有三个原因：第一，热方程、常微分方程和线性系统都有明确数学结构；第二，可以生成数据并独立构造参考真值；第三，任务规模适合个人机器运行。代价是实验主要代表受控合成问题，不能直接外推到实验室发现或开放世界科研。

项目围绕四个问题组织：

1. 三条任务是否具有完整的数据、环境、基线和独立自动评分?
2. 给予不同强度的方法指导后，Agent 能否形成有效提交?
3. 同一会话首次与最终候选相比，是否出现可核验的改进或退化?
4. 启用 thinking/max 的匹配对照，在提交、结果和输出用量上呈现什么差异?

第 4 项是在看到原结果后追加的探索性对照；后文“是否符合预期”的讨论是依据任务机制的事后分析，不冒充预注册的统计假设检验。

2. 相关工作调研与设计借鉴

下表比较了六项相关工作。前四项依据论文，后两项同时依据本地固定版本的官方源码。详细源码位置、工作流图与版本说明见调研文档。

工作	任务、环境与工具	评价方式	本项目借鉴及局限
AI Scientist-v2	提出假设，管理机器学习实验，执行代码并撰写论文；使用实验管理与树搜索	实验指标、图文检查和论文评审	借鉴“假设—实验—分析—修订”；论文质量与数值正确性不能用同一指标概括
ScienceAgentBench	从科研论文抽取数据分析任务，要求生成可执行 Python 程序	检查程序、运行产物与成本	借鉴可执行产物验收；完成指定分析不等于提出原创科学理论
MLGym	可执行的机器学习研究环境，支持方法实现、训练、实验及反馈迭代	任务性能指标及实验轨迹	借鉴公开反馈驱动的迭代；跨任务指标与计算预算需要分别校准
Darwin Gödel Machine	修改 Agent 自身代码，并保留不同后继版本	使用编程基准实测改动效果	帮助界定 RSI；编程能力提升不能自动等同于科学研究能力提升
ASI-Bench	在同一科研项目中改变方法指导信息，Agent 选择方法并调用工具	产物合法性门槛、任务评分、运行与评价状态	借鉴匹配的信息条件；本项目 G2 只给方向，不完全复刻其 B2 方法提示
Terminal-Bench-Science	专家设计的终端科研工作流；任务包包含指令、环境、测试和参考解	独立任务测试，并通过参考解、空操作和对抗检查维护质量	借鉴任务包、隔离执行和客观验收；真实任务的依赖维护与专家制作成本较高

两项主要参考各解决了一类问题：ASI-Bench 启发我们在保持任务目标和评分一致时，改变给 Agent 的方法指导；Terminal-Bench-Science 启发我们把题目做成真正可运行、可测试、可复查的任务包。本项目将两者结合，用三种指导强度研究同一数值任务，并将结果交给独立判题程序。

现有工作的共同挑战包括：任务和环境差异会干扰模型比较，最终分数难以解释过程失败，公开反馈可能被过拟合，以及真实科研的新颖性很难完全自动评分。本项目通过统一接口、固定预算、隐藏测试和细分失败状态降低这些问题，但并未解决全部开放科研评价难题。

3. Benchmark 任务与数据构建

3.1 三条任务分别考察什么

任务	通俗解释与研究难点	输入	必须提交的产物
T1 / Heat：热方程初场恢复	热量扩散会抹平细节；根据较晚、带噪、缺失的温度观测推回最初分布，需要防止噪声被放大	时空温度观测、扩散系数、256 点目标网格	每例一个 `u0.npy` 初场数组
T2 / ODE：稀疏动力学辨识	从多个初始状态的带噪轨迹中找出运动方程；既要拟合观测，又要用少量项预测新轨迹	6 条训练轨迹、2 条公开验证轨迹、时间和精确初值	一个 `(10,2)` 多项式系数矩阵 `model.json`
T3 / Poisson：稀疏求解优化	求解 `A U = B`；矩阵很大但多数元素为零，四个右端项可共享计算，要求既正确又快	稀疏矩阵 `A.npz`、四列右端项 `rhs.npy`	每例一个 `(n*n,4)` 的 `solution.npy`

三条任务使用统一候选入口：`python solve.py --input /input --output /output --seed 0`。Agent 可以读写研究工作区、调用终端、编写和运行 Python、进行局部试验并调用公开评估工具。它提交相对源码目录，由宿主复制为只读候选快照；最终提交必须引用已登记候选，不能由 Agent 自报一个分数代替程序产物。

3.2 数据来源、划分与清洗

数据来自明确的数学模型，属于**合成数据**，不是外部实测数据采集。每条任务生成 30 例，共 90 例；每份数据固定后，两批实验使用相同划分。

划分	每任务数量	三任务合计	易 / 中 / 难数量（每任务）	用途和可见范围
public-dev	6	18	2 / 2 / 2	Agent 研究时可见，获得有限的公开诊断反馈
author-calibration	12	36	4 / 4 / 4	作者基线和评测规则验收，研究 Agent 不可见
final-test	12	36	4 / 4 / 4	研究关闭后的独立最终评价，研究 Agent 不可见
合计	30	90	10 / 10 / 10	三种角色的数据彼此分开

Heat 用 32 个正弦模态构造初场，按热方程产生后续观测，再加入缺测和高斯噪声；难度随观测延迟、缺失和噪声改变。ODE 生成二维三阶多项式系统的多初值轨迹，并按通道幅度加噪；难点在于噪声导数、稀疏结构及长时预测。Poisson 构造正系数离散扩散矩阵及四列制造解，设 `B=A U*`；三个档位使用网格边长 32/64/128 和系数对比度 1/30/300。

“清洗”在这里指生成后的质量检查（QC）：数值是否有限、形状与参数是否合法、是否出现非预期重复、真值能否被独立方法交叉验证、文件是否完整。Heat 用独立传播方式和方程残差核对；ODE 用另一种积分器交叉核对；Poisson 检查矩阵性质及独立通量复算。**90/90 例通过 QC；没有根据 Agent 得分删掉困难样本。** 随机流由命名空间和根熵派生，文件保留 SHA256 以检查一致性。

仓库包含 18 例公开输入；完整 90 例输入、作者真值、QC 和生成记录在 Release 的 `author-data-v0.3.tar.gz`。详见数据索引、任务卡与逐文件清单。完整作者数据发布用于复核，但未来研究运行仍必须隔离真值；公开后的旧隐藏集不能继续被宣称为全新盲测集。

4. 实验设计与编号说明

4.1 G1、G2、G3 是指导强度

编号	提供给 Agent 的信息	本项目想观察的能力
G1	共同任务契约，加详细方法指导	能否把较明确的方法实现并完成实验
G2	共同任务契约，加研究方向；不提供具体算法名	能否从方向构建具体可行方案
G3	共同任务契约：目标、输入、工具、产物和约束	能否自主选择方法并验证结果

组别改变的是方法提示；输入、工具、预算、输出格式和科学成功条件保持一致。G3 仍有完整任务说明，并非没有任何信息。

4.2 r1、r2、r3 是什么

r 是 repeat（重复运行）的缩写。 例如，`Heat G2 r3` 表示“热方程任务、G2 方向指导组、第 3 次独立研究会话”。每次从新的研究工作区开始，不继承同组上一次的候选。重复运行用于观察同一条件下表现是否稳定。

必须区分以下三种“重复”：

标记或操作	含义	是否增加独立研究样本
r1 / r2 / r3	同一任务和指导组的第 1 / 2 / 3 个研究会话	是；但仍共享任务数据、模型和宿主条件，不代表独立数据集
a001 / a002	同一研究会话的执行尝试；a002 是明确关联的基础设施恢复重试	否；失败记录与开销另存，不把两次尝试算成两个科学样本
同一候选评分重放三次	提交后的程序在隔离环境重复执行，核对数值和运行表现	否；重复使用同一组 12 个测试实例，不变成 36 个独立测试例

`r2` 不是中等难度，`r3` 不是最终改进版，也不代表换了隐藏测试集。本轮求解器种子固定为 0；研究会话独立启动并不意味着拥有三个不同的数学数据种子。`first` 是可信登记中确定的首次候选，`final` 是会话最终指定候选；final 不是事后挑选隐藏成绩最高的版本。

4.3 为什么每批是 15 个会话

任务	G1	G2	G3	每批会话数
Heat	r1、r2、r3	r1、r2、r3	r1、r2、r3	9
ODE	r1	r1	r1	3
Poisson	r1	r1	r1	3
合计				15

这是小规模、非均匀重复的设计：只对 Heat 每组重复三次，ODE 和 Poisson 每组只有一次，不能据此比较稳定的组间优劣。原批次与对照批次按同一个“任务 × 指导组 × repeat”格子配对；两个批次分别分析，不合并成 30 次同条件样本。

4.4 模型、预算与对照条件

条件	原正式批次 formal-003	thinking/max 对照
研究框架	Harbor / 原生 Pi	相同框架；执行期间发生三次基础设施修复，见第 9 节
模型路由	`deepseek-flash`；冻结时记录为 DeepSeek-V4.1-Flash-1017	相同记录的路由；不能独立锁定供应商内部修订
thinking	disabled	enabled
effort	未设置	max
temperature / top_p	0 / 1	temperature 不生效，记录 null；top_p=1
单请求输出上限	4,096 token	4,096 token
每会话累计输出上限	200,000 token	200,000 token，包含 thinking、普通输出及原生压缩
每会话其他上限	1,800 秒；20 次公开评估	相同；任一预算先到则停止
数据、提示、评分与研究资源	冻结	保持原科学参数

两批冻结计划见原计划和对照计划。对照为事后追加，thinking 和 max 共同改变，temperature 语义也不同，且先后执行、中途修复，因此不是隔离单一变量的严格因果实验。此前选择性扩大到 50 万 token 的补跑已取消，其记录保留在补充附录，不进入这里的 15 格比较。

5. 运行环境、评测规则与隔离

5.1 从研究到评分的执行流程

1. **生成并冻结数据**：作者构造输入、参考真值和 QC，分开公开与隐藏部分。
2. **Agent 开展研究**：研究容器只能读取公开数据，编写候选并获得公开反馈。
3. **可信提交登记**：宿主对源码生成只读快照，记录候选 ID 与哈希。
4. **关闭研究**：本批全部研究关闭后，才开放最终隐藏评分；评分结果不会回灌仍在进行的研究。
5. **独立执行与判题**：全新 W 容器运行候选；J 容器读取数值产物及真值完成判断。
6. **保留全链证据**：记录分数、成功标记、资源与用量、候选版本、错误及原始日志。

实际环境为 M4 MacBook Air 上的 Colima Linux aarch64。研究容器 R 为 4 vCPU / 4 GiB；候选容器 W 为 1 vCPU / 4 GiB、单数值线程、无网络且禁 swap。数值环境固定 Python 3.12.12、NumPy 2.2.6 和 SciPy 1.15.3，镜像与源码哈希均留档。W 不接触真值和 Judge 代码；J 不运行候选源码，只检查产物。模型凭据由研究容器外的 relay 管理。

这一区分很关键：Agent 可以声称“已经正确”，但最终成绩来自独立程序对文件的检查。详见隔离协议和复现指南。

5.2 正确性、研究效果、效率与可复现性

维度	本项目如何测量	读数含义
正确性	文件格式、形状、有限数；隐藏数值误差和科学约束	程序是否交付了符合任务要求的结果
研究效果	任务连续分数；全例成功的 reward；first → final 差异	结果质量及会话内迭代是否改善
实验效率	输出 token、墙钟时间、公开评估次数；Poisson 完整批次速度	为获得产物付出了多少资源，求解器是否够快
可复现性	数据/源码/镜像哈希、冻结配置、候选快照、独立重放与日志	他人能否定位同一材料并重复核验；速度仍需新环境验收

5.3 三条任务的成功条件和分数

任务	单例科学门槛	全会话成功条件
Heat	初场相对误差 ≤0.15，未来场误差 ≤0.03	12 个 final-test 实例全部通过
ODE	阈值化后非零系数 K≤10；四条隐藏长轨迹的最大相对误差 ≤0.05，隐藏向量场误差 ≤0.05	12 例全部通过，且产物、积分及结构约束合法
Poisson	每列真实相对残差 ≤1e-8、解误差 ≤1e-5，资源合格	12 例均正确，并在合格计时窗口中达到 ≥1.5× 的批次加速

连续分数用于比较“离正确或高效还有多远”，reward 用于判断“是否完全达到门槛”，两者分别报告。设 `c(x)=min(1,max(0,x))`，有效单例/批次的核心评分式为：

- **Heat：** `100 × [0.8 c(1−E初场/0.30) + 0.2 c(1−E未来/0.06)]`。
- **ODE：** `100 × [0.5 c(1−E轨迹/0.10) + 0.5 c(1−E向量场/0.10)]`；产物、积分或稀疏约束失败按规则归零。
- **Poisson：** 在正确且正式计时有效时，`100 × c(log(speedup)/log(8))`，`speedup=三次基线耗时中位数/三次候选耗时中位数`。

Heat/ODE 按冻结规则汇总全部实例，并对候选独立重放三次。Poisson 将固定 Jacobi-CG 基线 B 与候选 C 按 **B、C、C、B、B、C** 交错运行，每批使用新容器；计入 Python 启动、导入、I/O、矩阵转换、分解及四个右端项求解，不采用候选自己打印的内部耗时。不同任务的分数含义不同，本报告不计算跨任务总平均分。

5.4 为什么必须区分零分和无效

正常无提交和科学失败可按冻结协议记零；基础设施错误或计时环境不合格缺少有效评价依据，应保留为空。Poisson 的宿主观察采用事前冻结规则：每 2 秒采样，先通过 30 秒准入窗口，测量期间继续观察，无新的 swap-out，且无超过 5% 单核占用的无关进程。轻微超限也必须保留拒绝记录，不能在看过成绩后改变门槛。

这不意味着数值正确性记录毫无价值。G2 的数值检查与原始耗时仍可以报告，但应与“正式性能成绩”分列，见第 7.4 节。

6. 作者基线：任务是否可解、评分是否有区分度

作者基线是人工预先实现的参考方法，不是额外 Agent 会话。三条任务共 11 种方法均在原正式批次完成运行。固定参考在研究开始前选定，未根据 final-test 成绩事后更换。下表为原正式批次结果；对照批次另有 10 项有效基线和 1 项 Jacobi 计时准入拒绝，不能用原批次成绩冒充其新测量。

任务	基线方法及直观含义	分数	正确例 / 12	reward	正式加速比
Heat	未正则化 LS：直接拟合全部模态	19.556	0	0	—
Heat	rank5：只保留低频五个模态	89.893	12	1	—
Heat	Tikhonov：用正则化限制不稳定解（固定参考）	93.271	12	1	—
Heat	discrepancy：按噪声水平选正则强度	91.651	12	1	—
Heat	TSVD：截去不稳定的奇异方向	92.192	12	1	—
ODE	原始差分：直接从噪声轨迹估导数	0.000	0	0	—
ODE	SG/STLSQ fixed：平滑后做稀疏回归（固定参考）	95.389	12	1	—
ODE	公开验证 search：仅用公开验证选参数	95.647	12	1	—
Poisson	CG：共轭梯度迭代	0.000	12	0	0.199×
Poisson	Jacobi-CG：固定速度比较器	0.014	12	0	约 1.000×
Poisson	LU 复用：一次分解求多个右端项（固定参考）	38.976	12	1	2.249×

数据来自基线表和正式结果报告。Jacobi 与自身比较的速度在重复执行中略有波动，因此显示约 1×，分数也可能略高于零。

这些结果符合任务机制：Heat 直接拟合会放大噪声，加入正则化后明显改善；ODE 的差分会放大噪声，平滑与稀疏回归更可靠；Poisson 三种方法都能解对，但只有合适的复用策略达到效率门槛。因此，本基准能够区分“运行成功”“数值正确”和“达到研究效果”。

按难度检查，Heat 固定参考的易/中/难均分为 93.622 / 95.195 / 90.997，ODE 为 98.934 / 96.744 / 90.490；每档四例均通过。ODE 随噪声增加而下降，符合预期；Heat 中档高于易档，提示小样本下难度标签不必严格对应分数排序。分难度完整表保留全部方法，不能只挑有利结果。

7. Agent 实验结果

7.1 总体结果

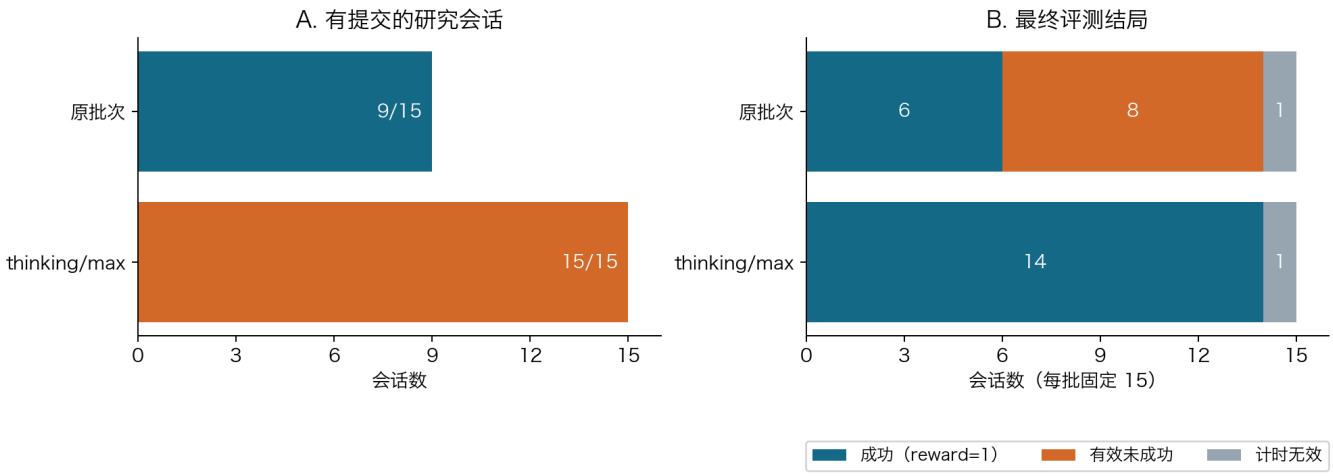


图 1。 左图统计是否形成通过公开产物检查的提交；右图统计正式最终结局。原批次 8 项“有效未成功”包括 6 项正常无提交零分和 2 项有提交但未达标。两批各有 1 项计时无效，不计为科学零分。

指标	原批次：thinking 关闭	thinking/max 对照（含 G1 后续计时）
计划研究会话	15	15
有提交	9 / 15（60.0%）	15 / 15（100%）
有效最终评分	14 / 15	14 / 15
成功，reward=1	6 / 15（40.0%）	14 / 15（93.3%）
有效但未成功	8	0
计时无效	1	1

成功比例以全部 15 个计划会话为分母，同时单列无效项。不能把对照“14 个有效评分全部成功”写成“15 个任务全部成功”。此外，有提交不等于全部科学条件通过。

7.2 按任务、指导组和重复次数排列的完整成绩

下表是同一任务格子的配对结果。原无提交的零分保留；Poisson G2 两批都缺少有效正式分数；G1 新分来自后续获准的独立计时窗口，历史拒绝保留。

序号	会话	原最终分	thinking/max 最终分	差值	原 reward → 新 reward	说明
01	Heat G1 r1	93.631	93.388	-0.243	1 → 1	两批均有提交
02	Heat G1 r2	0.000	93.627	93.627	0 → 1	原无提交，按协议记 0
03	Heat G1 r3	0.000	91.957	91.957	0 → 1	原无提交，按协议记 0
04	Heat G2 r1	87.210	93.328	6.118	0 → 1	两批均有提交
05	Heat G2 r2	19.553	93.637	74.084	0 → 1	两批均有提交
06	Heat G2 r3	0.000	93.688	93.688	0 → 1	原无提交，按协议记 0
07	Heat G3 r1	91.532	93.041	1.509	1 → 1	两批均有提交
08	Heat G3 r2	0.000	93.625	93.625	0 → 1	原无提交，按协议记 0
09	Heat G3 r3	0.000	93.424	93.424	0 → 1	原无提交，按协议记 0
10	ODE G1 r1	96.551	99.266	2.715	1 → 1	两批均有提交
11	ODE G2 r1	98.793	99.266	0.473	1 → 1	两批均有提交
12	ODE G3 r1	99.068	98.994	-0.074	1 → 1	两批均有提交
13	Poisson G1 r1	44.308	68.376	24.068	1 → 1	新分采用获准的独立计时补测
14	Poisson G2 r1	—	—	—	— → —	数值通过；两批正式计时无效
15	Poisson G3 r1	0.000	44.169	44.169	0 → 1	原无提交，按协议记 0

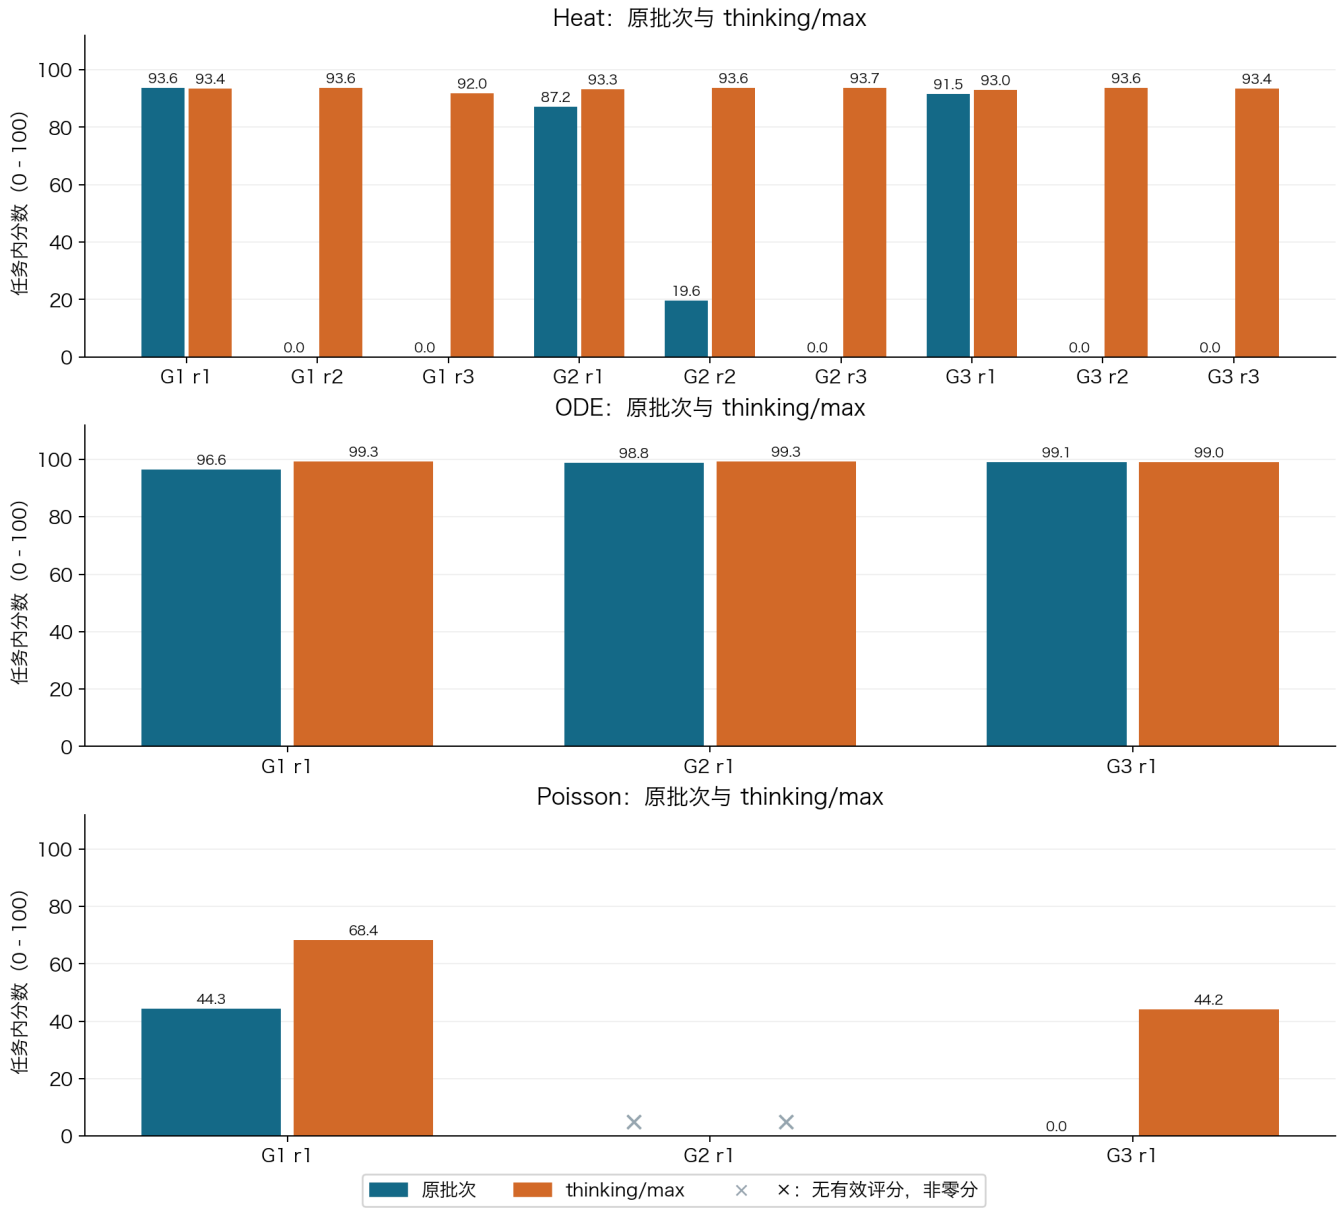


图 2。 每个子图只比较同一任务。叉号表示缺少有效分数，位置仅用于标记，不能当作低分；零分则是正式协议下的有效结果。柱上数字为显示取整，精确值见表格及 JSON。Poisson G1 的新分包含独立计时窗口变化，不能把其全部分差解释为模型效果。

全部 15 格中，14 对有可比较的有效分数：12 对提高、2 对降低；剩余 1 对不可比较。其中 6 对提高来自原无提交。只看两批都有提交且评分可比较的 8 对，结果是 6 升、2 降。Heat 对照九次均通过 12/12，分数范围 91.957–93.688；ODE 三次均通过 12/12，范围 98.994–99.266。

Heat 对照 G1/G2/G3 的中位分分别为 93.388 / 93.637 / 93.424，彼此接近；每组只有三次，不能把这个排序当作指导组稳定优劣。ODE 与 Poisson 每组仅一次，更不宜做显著性结论。

7.3 thinking/max 会话内迭代与资源

`first → final` 描述一次研究中候选的变化，与"原批次 → 对照批次"的配对差异不是同一个量。下表保持与成绩表相同的顺序；最后一列保留冻结计划中的实际执行序号。

序号	会话	first 分	final 分	公开评估次数	输出 token	研究用时（分钟）	实际计划序号
01	Heat G1 r1	93.271	93.388	3	74,089	30.04	3
02	Heat G1 r2	93.271	93.627	2	41,650	5.16	11
03	Heat G1 r3	93.271	91.957	4	50,041	6.09	14
04	Heat G2 r1	93.328	93.328	1	92,474	10.79	1
05	Heat G2 r2	93.637	93.637	1	45,855	5.57	12
06	Heat G2 r3	93.627	93.688	2	43,887	6.17	15
07	Heat G3 r1	93.625	93.041	2	57,574	9.30	2
08	Heat G3 r2	93.625	93.625	1	62,324	11.82	10
09	Heat G3 r3	93.625	93.424	3	65,281	10.36	13
10	ODE G1 r1	99.266	99.266	1	85,921	30.03	4
11	ODE G2 r1	99.266	99.266	1	30,937	23.64	5
12	ODE G3 r1	99.266	98.994	3	63,839	27.74	6
13	Poisson G1 r1	64.342	68.376	3	57,022	10.82	9
14	Poisson G2 r1	—	—	2	75,260	11.10	8
15	Poisson G3 r1	43.204	44.169	3	50,056	16.16	7

公开评估次数不等于全部终端试验次数。输出 token 包括 thinking、普通输出及原生压缩；这里的用时是日志记录的研究墙钟，超时会话在截止后的关闭检查使读数略超过 30 分钟，不代表额外延长实验预算。

对照批次 first → final 为 **5 升、4 降、5 个源码相同、1 项不可比较**。例如 Heat G1 r3 从 93.271 降至 91.957，ODE G3 r1 从约 99.266 降至 98.994。实验反馈之后继续修改，未必改善隐藏成绩。相同源码显式复用已有重放结果，不把 first 和 final 算成两个独立研究样本。

输出用量口径	原批次	thinking/max 对照
15 个保留研究 attempt 的已知输出 token	2,324,341	896,210
加上旧失败 attempt 的已知输出 token	2,591,496	925,815
全部 attempt 的代理 charged 输出额度	2,613,274	929,911
保留研究墙钟合计	约 5.276 小时	约 3.580 小时

charged 是代理扣减的额度，包含对不完整失败请求的保守计数，不是供应商货币账单。对照中共 17 个 attempt，两个是保留失败记录的关联重试；原批次成本另包含四个无效 attempt。对照输出更少是已观测到的事实，但会话是否早停、重复调用减少、执行器修复等也会影响用量，不能据此认定 thinking 天然更省成本。

7.4 Poisson G2：保留实测值，明确诊断资格

G2 有合法候选，并在两轮测量中均完成三次候选批次；每次都通过相同的 **12/12 个隐藏实例**。最近一轮最大相对残差约 2.29×10^{-16}，最大相对解误差约 8.24×10^{-13}。这些是保存的数值检查结果；同一实例重复运行不能增加独立样本数。

测量	基线中位耗时（秒）	G2 中位耗时（秒）	原始耗时比（仅诊断）	正式分数
首次测量	1.141403	0.452240	2.524×	未取得有效计时，留空
独立补测	1.095766	0.440336	2.488×	未取得有效计时，留空

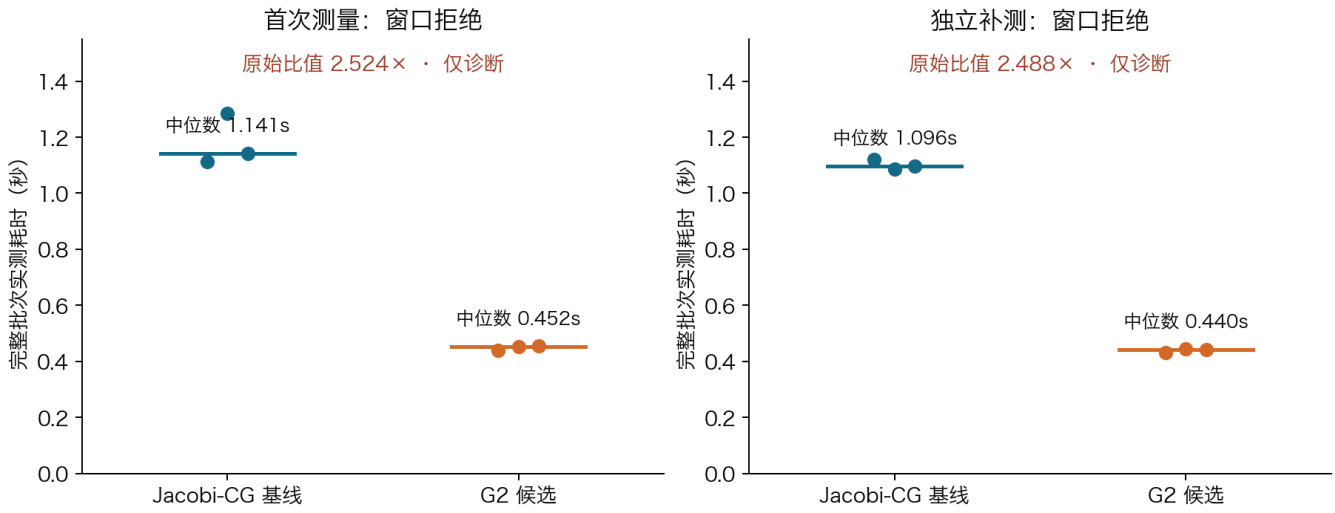


图 3。 每个点代表一次完整批次耗时，短横线为三次中位数。两个窗口都被拒绝，因此图中的原始比值不是正式加速比，不换算成正式分数，也不计入成功数。

最近一次拒绝来自一个约 2.028 秒的区间：VPN 进程增加约 0.11 秒 CPU，用量折算为 5.423%，略高于冻结的 5% 单核阈值。没有新增 swap-out；记录的 swap-in 仅作诊断。首次窗口则同时出现其他进程活跃和 swap-out。两轮比值接近，支持“候选有加速迹象”的诊断描述，但不能证明环境干扰没有影响。

本报告采用最近补测的**实测 2.488×**作为明确标注的诊断数值，不估填分数。完整记录见计时报告、补测结果与宿主观察。正式性能仍待合格环境中的新测量；本次报告整理没有启动新的 Agent 或测量。

8. 端到端案例：一次可核验的迭代改进

原批次 **Heat G3 r1** 展示了完整链条。Agent 在只有共同契约的条件下实现求解器并试验；公开反馈返回观测残差和粗糙度，不返回隐藏真值。宿主登记 first=`candidate-017`、final=`candidate-018`，研究关闭后分别进行三次独立隐藏重放。

项目	首次候选	最终候选
隐藏分数	21.394	91.532
正确实例	0 / 12	12 / 12
reward	0	1
源码中的正则化参数 λ	0.0001	0.1

两个候选源码的唯一差异为 λ 默认值。对一个公开例，观测残差比从约 0.906 升至 0.982，而粗糙度从约 2774.7 降至 44.8。这说明方法容许略大的观测拟合误差，以换取更平滑、稳定的初场估计；独立隐藏评分验证了该次修改的收益。它符合逆问题正则化的机制，但不意味着所有数据上越大的 λ 越好。

下面是原始登记事件的**字段节选**：


```
{"kind":"registry_closed","fields":{"attempt_status":"completed","first_id":"candidate-
017","final_id":"candidate-018"}}
```


对应独立评分节选：


```
{
  "first": {"checkpoint_id":"candidate-
017","replay_count":3,"score":21.394330950607056,"reward":0},
  "final": {"checkpoint_id":"candidate-
018","replay_count":3,"score":91.53191716630722,"reward":1}
}
```


可追溯来源：研究事件、隐藏评分 JSON、源码差异、完整节选及 SHA256。这里的机制解释来自代码和数值证据，不补写 Agent 没有记录的研究假设。

本项目也保留反例：原 Heat G2 r1 从 93.791 降至 87.210，通过数从 12 降至 11。只展示成功案例会夸大迭代收益，因此完整表格同时包含改进、退化、未改变和无提交。

9. 结果分析：是否符合预期，原因是什么

9.1 对设计设想的逐项检查

设计设想或合理预期	实际观察	判断与可能原因
三条任务应可运行、可独立核验，并存在可成功的方法	90 例 QC 通过；11 种作者方法完成原批次检查；三任务均有端到端成功案例	达到本项目工程目标；至少三任务基线与至少一项端到端验证的作业要求均已覆盖
正则化、去噪和结构约束应比简单拟合更稳健	Heat LS 与 ODE 原始差分失败，强基线全部通过	符合机制预期：逆问题及数值微分会放大噪声
正确性通过并不保证计算效率达标	Poisson CG 数值通过 12/12，却仅 0.199×；LU 为 2.249×	符合预期：求解策略与重复 RHS 复用决定效率
更多方法指导可能提高完成的稳定性	原 Heat 各组重复差异明显；对照组分数接近；未呈现可靠的 G1>G2>G3 排序	证据不足；样本少，接口行为和研究路径可能掩盖提示影响
研究迭代可能提高隐藏表现	原批次可比较会话 2 升、1 降、5 源码不变；对照 5 升、4 降、5 相同	部分符合；公开反馈是代理指标，继续修改也可能过拟合或破坏有效方案
thinking/max 对照可能改善完成率	有提交从 9/15 到 15/15，14 对可比分数中 12 升	描述性支持，但无法分离 thinking、max、执行器修复及顺序影响
同一机器的计时仍应通过环境验收	G2 两轮存在超阈值背景活动；G1 在新窗口才通过	宿主噪声是实际限制；有数值解不等于取得合格速度证据

9.2 失败模式不能全部归为“模型不会做”

原批次的无提交包含不同过程：有的反复调用相同工具，有的只是输出文件名递增，有的持续做不同随机模拟却没有完成登记。62 次公开评估中还存在 24 次源码导出失败。它们提示，接口可理解性、停止策略和从试验到交付的衔接会影响结果；不能只从一个零分推断数学能力。提交诊断保留原始参数与输出哈希依据。

对照过程中出现三类基础设施问题，均保留原始证据：

问题	影响与处理	报告中的统计方式
relay 将输入 usage 下调误判为错误	Heat G3 r1 a001 失败；修复后关联 a002 重试	旧失败及 25,070 已知输出保留；两个 attempt 仍属一个研究格子
Pi 在纯 thinking 达到 4,096 上限后未续接	Heat G1 r1 a001 仅 4,535 输出便结束、无提交；修复后关联 a002	保留原 completed 标签，但注明协议缺陷，不解释为 Agent 主动完成
续接未进入原生上下文压缩路径	Heat G1 r1 a002 出现 252 次单 token 无进展响应，最终按原 30 分钟关闭，保留候选	原 research_timeout、74,089 输出及 3 次公开评估保留；未再重跑已有候选

后续上下文衔接修复后继续未开始会话。最终版本留下 378 项完整测试通过、11 个原生循环和 4 个完整 AgentSession 用例通过的日志；这些是基础设施验证，不是额外科学样本。修复没有增加每请求 4,096 或每会话 20 万预算，但改变了执行行为，因此是比较时必须披露的因素。详见对照报告与修复证据。

9.3 本实验能与不能支持的结论

可以支持：任务和基线可运行；候选输出可独立核验；某些迭代确实改善隐藏指标；对照批次观察到更高提交率；失败可以区分为数值、提交、协议和计时问题。

尚不能支持：thinking 单独导致了全部提升；G2/G3 稳定优于 G1；一个模型代表所有研究 Agent；在公开后的旧隐藏集上仍保持全新盲测；或者系统已具备原创科学发现及 RSI 能力。每个任务只有 1 或 3 次组内重复，未进行有充分统计功效的显著性检验，也不把评分重放次数充当样本量。

10. 后续改进方向

优先方向	可实施改进	希望解决的问题与验证方式
提交接口	在新版本明确相对目录、入口和错误原因，增加小型提交演练	减少 empty tar 等非科学失败；在新冻结版本比较提交率
对照公平性	固定修复后的执行器，随机化运行顺序；分别控制 thinking 与 effort	降低基础设施和时间顺序混杂；使用新计划及新隐藏集
样本规模	ODE/Poisson 也增加组内重复，并引入更多模型和数据种子	估计方差，再开展有意义的组间统计比较
任务难度	扩大系数族、观测方式和迁移范围，检验强方法是否接近饱和	避免对当前合成分布过度适配；分层报告难度
性能测量	使用安静的专用宿主，提前确定观察与重测政策	减少 G2 类计时拒绝；完整保留每个窗口，不择优报告
研究过程	记录实验假设、修改与反馈的对应关系，分离重复调用和有效试验	更精确地分析一次改进来自哪里，避免用 HTTP 成功数代替研究进展
RSI 扩展	将 Agent 策略或工具代码作为改进对象，用未参与优化的新任务验收	从“优化当前求解器”扩展到可迁移的自改进；需要单独的安全和评价设计

这些改进属于后续新版本，不会追溯修改本次冻结参数、旧失败或隐藏分数。

11. 作业要求对照、复现与交付

作业要求	已完成内容	入口
调研相关 Benchmark 与 RSI	六项工作，比较任务、工具环境、评分与局限	第 2 节、完整调研
五选一研究领域	科学计算	第 1、3 节
至少 3 条完整任务与基线验证	Heat / ODE / Poisson；90 例 QC；11 种作者方法	第 3、6 节、任务卡
可复现环境与独立评分	固定依赖、R/W/J 隔离、只读候选快照、隐藏真值隔离	第 5 节、环境与复现
至少 1 条 Agent 端到端验证	三任务均完成；Heat G3 r1 提供完整实例和日志	第 7、8 节、证据链
结果、失败及可靠性分析	两批 15 格配对、全部失败/重试/拒绝，局限与改进	第 7、9、10 节
个人 GitHub 完整提交	代码、数据索引、公开输入、基线、评分脚本、日志与完整附件	仓库、Release

读者可先使用 Python 标准库核验已有交付，无需调用模型或启动 Docker：

```
git clone https://github.com/bxf1/sciresearch-bench-lite.git
cd sciresearch-bench-lite
python3 tools/verify_delivery.py
```

按任务、组别和 repeat 重新生成本报告的数据表：

```
python3 tools/build_final_report.py
```

此命令仅读取既有结果，生成排序表与JSON。制图和离线 HTML 的依赖及命令见复现指南。实际数值复现需要锁定的 Python/Docker 环境和作者数据；重放已有候选不需要模型 API，新 Agent 研究才需要供应商凭据。

原实验记录保留在 `research-runs/` 与 `logs/`；大型轨迹和作者数据使用 Release 独立命名附件保存。历史标签的自动源码 ZIP 不是最新 main 的报告版本。最终阅读以本报告和 README 为入口，历史专项报告用于追溯各阶段，不把后来结果伪装成早期已知结果。

12. 结论

本项目完成了一套小规模科学计算 Auto Research Benchmark：三条任务、90 个合成实例、11 种作者基线、隔离运行与独立评分，以及两批各 15 个研究会话的实测分析。作业要求的三任务基线检查和至少一次端到端验证均已实现。

实验显示，受控数值任务能够揭示研究 Agent 在方法选择、实现、提交和迭代上的差异：正则化与结构方法改善了科学结果，候选迭代有收益也有退化，thinking/max 对照观察到更高提交率。Poisson G2 的数值正确性与约 2.488× 诊断耗时比也被如实保留，其正式性能成绩仍为空。评价一个自主研究系统，需要同时查看产物、独立评分、失败证据和资源开销，不能仅依靠一张最终分数表。

由同目录 Markdown 报告生成；图像已内嵌，可离线阅读。外部证据链接指向公开仓库。