SciResearch-Bench-Lite
九组 r1 完整实验报告

完整实验结果 · Heat / ODE / Poisson × G1 / G2 / G3 × r1

实验范围为 Heat、ODE、Poisson 三任务与 G1、G2、G3 三类指导配置。本文依次介绍问题、GT、规则与校验、开发集、九组探索、测试结果、结论与问题分析。所有成绩均来自封存源码及有效评分记录。

本文汇总九组配置的完整有效结果：九组均封存最终源码，主测试均三次 12/12 通过，reward 均为 1。全部执行记录包含 10 个研究会话；已知输出 575,944 token，预算计入 739,784 token。主任务与独立诊断分别分析，所有执行记录保留。

1. 问题定义与实验条件

1.1 三类科学计算任务

本实验评估 Agent 能否在有限预算内，理解数据与接口、选择数值方法、开展本地实验、登记可执行候选，并在未知实例上满足精度和资源要求。一个科学样本是一个完整的 Agent 研究会话。测试实例、源码版本、计时重放和基础设施重试都不是新增的独立 Agent 样本。

任务	已知输入与输出	科学难点	正式验收
Heat 反向热传导	由有噪、部分缺失的温度观测恢复 256 点初场；输出 `u0.npy`	扩散会抑制高频，直接求逆放大噪声；观测残差小不保证初场正确	初场相对误差 ≤ 0.15，未来场相对误差 ≤ 0.03
ODE 动力系统识别	从公开轨迹拟合二维三次多项式向量场；输出 10 × 2 系数矩阵	数值微分放大噪声，支撑选择与轨迹拟合可能有不同偏好	最多 10 个非零系数；最大轨迹误差与场误差均 ≤ 0.05
Poisson 稀疏求解	给定变系数离散算子和四个 RHS，输出四组解	精度、稀疏结构、预处理复用与启动开销共同决定效率	残差 ≤ 10^{-8}、解误差 ≤ 10^{-5}，正式端到端加速比 ≥ 1.5

Heat 在区间 [0,1] 上满足 $u_t = \kappa u_{xx}$，边界为零。ODE 主任务是带线性与非线性阻尼的 Duffing 系统：$\dot{q}_1 = q_2$，$\dot{q}_2 = -aq_1 - bq_2 - cq_1^3 - dq_1^2 q_2$。Poisson 使用正系数、零 Dirichlet 边界和调和平均边系数构成对称正定五点离散系统 $AU = B$。

1.2 保持一致的研究条件

项目	冻结条件
报告配置	9 组 r1 配置；每任务 G1/G2/G3 各一组结果，实际研究次数单列统计
指导差异	G1 提供详细方法指导；G2 提供方向指导；G3 自主探索
共同预算	30 分钟、20 次已接受公开评估、200,000 输出 token（含 thinking 与压缩）
单次模型请求	上限 16,384 token；正常上下文压缩保留
研究容器	4 vCPU / 4 GiB
候选执行容器	1 vCPU / 4 GiB；单数值线程；无网络、无 swap；128 进程上限
候选运行限制	Heat / ODE 每批 120 秒；Poisson 每批 60 秒；输出 256 MiB；临时空间 64 MiB
源码快照	独立相对目录，最多 20 MiB / 1,000 文件；完整导出及哈希核验

模型路由冻结为 deepseek-flash；启动前取得的服务商文档映射为 DeepSeek-V4.1-Flash-1017，启用 thinking，effort 为 max。该信息是服务商声明的别名映射，不能证明后端权重在运行期间具有不可变身份。共同提示、工具 schema、执行器代码、镜像、依赖和可取得的版本信息均保存哈希。模型版本证据

研究均串行执行，共同提示、资源和预算保持一致。九组配置共有十个独立研究会话，ODE G1 对应两次，其余各一次。结果表使用各组选定的最终候选，全部会话的成本和执行记录均保留。

1.3 评分与解释边界

Heat 连续分为 100 × [0.8 clip(1 − E_init/0.30, 0, 1) + 0.2 clip(1 − E_forward/0.06, 0, 1)]。ODE 连续分为 100 × [0.5 clip(1 − E_roll/0.10, 0, 1) + 0.5 clip(1 − E_field/0.10, 0, 1)]。二者先按实例计算，再在测试集和规定重放中汇总。

Poisson 连续分为 100 × clip(log(S)/log(8), 0, 1)，S 为三次基线端到端时间的中位数与三次候选时间中位数之比。数值失败是合法零分；计时环境无效则保留数值结果并令正式分数为 null，不能以 0 代替。

三任务使用不同分数含义，本文不计算跨任务总平均分。每组只报告一个选定结果，实际执行次数并非均衡重复设计，因此不进行指导强度的显著性排名，也不推断某组普遍更优。

2. 生成 GT 与独立核验

2.1 随机性、划分与去重

本批使用新的私有根熵，由任务、用途、主题与实例索引构成独立随机命名空间。同一任务三组使用完全相同的数据。生成后不根据参考方法或 Agent 得分换种子、删除难例或重新抽题。

划分	每任务	三任务合计	用途
公开开发集	6	18	Agent 探索与反馈
主任务作者校验集	12	36	GT、规则与参考方法验收
主任务测试集	12	36	正式主分
诊断作者校验集	12	36	新增题与运行可行性
诊断测试集	12	36	只执行封存最终候选

总计 162 个实例。Poisson 诊断主题的正序、逆序及主题视图是同一批文件的字节一致副本，不增加实例数。完整实例与潜在系统的去重规则保留。主任务易例在对比度为 1、网格相同时会自然得到相同恒系数算子，独立 RHS 仍构成不同实例；这一既有例外保持不变。中高难度算子的重复只允许在预声明的缓存诊断配对中发生：同一划分内两个不同算子各配两组独立 RHS，复用对明确标记。GT 与文件校验

2.2 Heat：解析模态与独立变换

初场使用 32 个正弦模态；主任务谱衰减指数在 [1.5, 2.5] 抽取，连续 RMS 归一化为 1。扩散系数 κ 在 [0.5, 1.5] 抽取。各模态按 $\exp(-\kappa\pi^2k^2t)$ 解析衰减。噪声按干净观测 RMS 缩放，易、中、难噪声比例为 0.005、0.01、0.02，随机缺失率为 0、0.15、0.30。

GT 以解析模态值生成，再与独立变换实现核对；同时检查初场、零边界、前向传播与半群关系。评分器会对提交的 256 点输出构建完整 256 模态正弦插值，不将提交结果截为 32 模态。这样可避免隐藏高频污染被评分器忽略。

2.3 ODE：方程、积分器与能量关系

主任务从 Duffing 系数分布生成动力学。公开数据包括 6 条训练轨迹和 2 条 validation 轨迹，时间区间 [0,6]、301 点；私有轨迹采用不同初值和 [0,8]、401 点，并在 21 × 21 状态网格检验向量场。

GT 使用高精度 DOP853，并以 Radau 独立积分交叉验证；检查多项式库展开、系数与真实方程的一致性，以及解析能量关系。两套积分器在同一解上的相对偏差要求低于 10^{-8}。真值积分与评分积分分离：GT 使用更严格容差，评分使用固定 DOP853 容差及每轨迹超时约束。

新增稳定三次系统为：

$$\dot{z}_1 = -az_1 + \omega z_2 - cz_1^3 - ez_1z_2^2$$
$$\dot{z}_2 = -\omega z_1 - bz_2 - dz_2^3 - ez_1^2z_2$$

a、b、c、d、e 独立取 U(0.2,0.8)，ω 取 U(0.5,1.5)。对 $V = (z_1^2 + z_2^2)/2$，有 $\dot{V} = -az_1^2 - bz_2^2 - cz_1^4 - dz_2^4 - 2ez_1^2z_2^2 \le 0$。该系统有 8 个非零系数，仍在原多项式库和最多 10 项的接口约束内，同样完成积分器、库展开和能量检查。

2.4 Poisson：制造解与离散算子

主任务网格为 32、64、128，系数对比度为 1、30、300，几何由三个圆区域组成。先构造 U*，再以浮点稀疏乘法生成 B = fl(AU*)。制造解提供已知目标，但评分同时检验相对残差与解误差，不能仅凭残差推断解精度。

独立核验包含通量形式重建、8 × 8 小规模直接求解，以及制造 RHS 的舍入误差界。增大网格、五圆及缓存主题采用相同核验逻辑；缓存主题使用不同算子 A、B 的交错输入顺序及逆序，检查实现是否错误地按位置或旧 RHS 复用结果。

3. 定义规则、校验集与验收

3.1 规则与 GT 的独立性

规则从任务定义、数值误差、输出接口和资源限制出发冻结。主任务评分分母、门槛及分布保持不变。新增诊断只更改预声明的数据条件；Heat 幅度诊断相应使用实际幅度核验真值归一化，避免把合法的 0.5 倍或 2 倍场误判为 GT 损坏。

主任务作者校验集与诊断作者校验集各 36 例。对全部 72 例，真值导出程序通过评分规则检查，零输出错误对照触发科学失败。真值导出只用于核对规则，不计为可用求解算法，也不计为 Agent 成绩。

评分测试覆盖阈值两侧、恰等于阈值、错误形状、NaN/Inf、超时与 GT 损坏。主任务生成器对 9 个一次性回归样例的输入及私有文件逐字节保持一致，避免新增诊断改变主任务。

3.2 主任务参考方法

任务	作者方法	通过 / 12	校验数值分
Heat	无正则 LS	0 / 12	19.599
Heat	5 模态 LS	12 / 12	83.346
Heat	固定 Tikhonov	12 / 12	89.275
Heat	discrepancy Tikhonov	12 / 12	88.027
Heat	TSVD	12 / 12	89.410
ODE	原始差分	0 / 12	0.000
ODE	固定平滑 + STLSQ	12 / 12	95.871
ODE	公开验证选参	12 / 12	96.911
Poisson	CG	12 / 12	—
Poisson	Jacobi-CG	12 / 12	—
Poisson	LU 复用四 RHS	12 / 12	—

表中都是作者校验集结果，不是私有测试结果。Poisson 此表仅进行数值校验；正式性能校验另用三组 BCCBBC，LU 参考加速比分别为 2.339、2.337、2.342，均达到冻结效率档要求的 1.8 倍校验门槛，因此保持主任务 1.5 倍成功门槛。正式计时校验

3.3 诊断参考方法与运行可行性

任务 / 主题	方法	通过	整批运行秒
Heat / 全部主题	固定 Tikhonov	10 / 12	0.445
ODE / 全部主题	固定平滑 + STLSQ	11 / 12	0.443
Poisson / 256 × 256 网格	LU 复用四 RHS	4 / 4	1.113
Poisson / 五圆系数	LU 复用四 RHS	4 / 4	0.442
Poisson / 交错算子 / RHS	LU 复用四 RHS	4 / 4	0.445

诊断参考方法必须在规定资源内执行并产生合法输出，诊断精度结果如实保留。Heat 10/12、ODE 11/12 的参考通过数说明固定参考方法已有边界；它们不构成更换样本的理由。全部 GT 与规则检查独立通过，因此这里没有将算法失误改写成题目无效。

3.4 执行器与资源验收

启动前完成 412 项测试、11 项运行隔离探针、5 项计时探针及真实资源压力验收。模型侧完成离线原生测试、三次请求的合成上下文交接探针和新镜像请求策略捕获：单次输出上限为 16,384，正常压缩后仍恢复该上限。原生工具事件增加宿主时间戳和单调时钟字段，用于探索时间线，不能替代正式性能计时。

计时观察器检查宿主负载、其他容器与 swap。一次候选最多进行三次实际 BCCBBC 测量；未执行候选的安静窗口准入检查另限 12 次。该区分在冻结前明确记录，所有拒绝窗口保留，仍采用首次有效测量，绝不挑最快值。校验期间出现的宿主后台负载没有通过降低门槛规避。验收与冻结

4. 开发集与可见反馈

每任务提供 6 个公开开发实例，主任务易、中、难各 2 例。G1/G2/G3 共用数据、工具、预算、共同说明及提交提醒，只有方法指导强度不同。私有 GT、作者校验集、主测试集和诊断测试集均不挂载到研究环境。

任务	Agent 可用的公开信息	使用与解释
Heat	有噪观测、位置、时间、κ、目标网格；公开反馈为归一化观测残差 R 与粗糙度	可做正则化选择和合成试验；R 接近 1 或下降不等价于恢复真值改善
ODE	train 与 validation 两部分带噪轨迹、时间网格、多项式库；公开轨迹反馈	两部分均是开发数据，允许联合拟合；私有测试才能支撑独立泛化结论
Poisson	算子、四个 RHS、数据接口、公开残差与诊断时间	可检查精度和优化方向；公开粗计时不能代替宿主隔离的正式 BCCBBC

Agent 自主决定何时探索、登记和提交。剩余 10、5、2 分钟的提醒只在可交互模型调用边界注入；长命令可能延迟提醒，报告不假定提醒必然及时改变行为。30 分钟硬截止不延长：显式提交使用指定候选，否则使用最新合法登记候选并标注 deadline_fallback；没有候选按规则记零。

5. 九组 Agent 在开发集上的探索

5.1 交付、用量与探索记录

会话	首次合法 / 分钟	评估请求 / 接受	源码版本	可见 shell 命令	结束状态
Heat G1 r1	8.63	1 / 1	1	23	主动结束
Heat G2 r1	6.80	1 / 1	1	36	主动结束
Heat G3 r1	18.44	2 / 2	2	28	主动结束
ODE G1 r1	8.02	3 / 3	3	41	主动结束
ODE G2 r1	26.02	1 / 1	1	24	主动结束
ODE G3 r1	7.63	2 / 2	2	30	主动结束
Poisson G1 r1	10.58	2 / 2	2	49	主动结束
Poisson G2 r1	16.54	1 / 1	1	32	主动结束
Poisson G3 r1	3.63	2 / 2	2	51	主动结束

组别	研究会话数	研究分钟（全部）	已知输出 token	预算计入 token	最终选择
Heat G1 r1	1	8.82	71,665	71,665	显式提交
Heat G2 r1	1	7.77	58,799	58,799	显式提交
Heat G3 r1	1	19.67	81,876	81,876	显式提交
ODE G1 r1	2	48.38	85,923	85,923	显式提交
ODE G2 r1	1	26.31	34,957	34,957	显式提交
ODE G3 r1	1	9.56	45,828	45,828	显式提交
Poisson G1 r1	1	15.68	93,464	142,616	显式提交
Poisson G2 r1	1	19.49	56,183	170,871	显式提交
Poisson G3 r1	1	11.19	47,249	47,249	显式提交

运行期请求证据：共 40 次响应的已知输出超过 4096 token，最大为 16,122 token；原生压缩请求共 4 次。16,384 是单次请求上限；原生压缩及续接/上下文剩余额度可以请求更少 token。单 token 请求共 0 次。

请求层失败与恢复。 原生请求重试发生在同一研究 attempt 内，不增加科学会话数。下表时间是失败请求实际占用时间，不含退避，也不从研究总成本扣除。未知输出按冻结策略计入保留额度；“已知输出为零”不表示实际生成量为零。

会话 / attempt	失败请求	占用请求秒	输出未知请求	失败请求计入预算 token
Poisson G2 r1 / a001	7	725.2	7	114,688
Poisson G1 r1 / a001	3	142.4	3	49,152

评估请求数按宿主收到的 evaluate 请求计数，另列接受次数；独立版本数按源码哈希计数；工具记录中的 shell 命令数只衡量可观察活动。单条命令可能包含多个拟合或扫描，也可能只是读取文件，因此不将命令数直接命名为“实验次数”。每组方法分析列出日志能确认的本地实验，无法观察的内部尝试不推测。

预算按单个研究会话执行；基础设施重试与独立科学会话在记录中区分。探索表描述纳入结果的会话，成本表包含全部实际会话。ODE G1 的 2 次会话共 48.38 分钟，分别受各自 30 分钟硬截止约束，不表示单个会话放宽预算。

5.2 Heat G1 r1：SVD 后验计算与能量约束的先验选择

方法。 使用 32 模态前向矩阵，通过加权矩阵 SVD 计算高斯条件均值和方差，再用含均值平方、后验方差和 Student-t 先验尺度的迭代更新调整各模态方差。自由度固定为 4；前两个模态使用宽先验，尾部初始方差按 k^{-3} 衰减。检查总后验二阶矩是否达到 1.95，依次尝试尾部尺度 0.25、0.5、0.9；异常时回退至截断 SVD。

探索路径。 先分析六例观测的奇异值、可辨识模态和频谱能量，建立本地估计库，再比较固定 Tikhonov、截断方法和重尾先验，扫描先验参数，并用开发集估计谱生成再观测模拟。若干本地模拟命令发生程序错误，Agent 修改后继续完成试验。共 23 条 shell 命令，但仅登记 1 个独立候选；首次合法登记为 8.63 分钟。

关键修改与选择。 探索期修改了迭代更新和模拟中的维度处理，最终采用 SVD 数值实现、尾部尺度选择和兜底逻辑。candidate-001 为首次和最终候选，显式提交后主动结束。因此正式首次/最终结果应复用同一源码哈希，不能把单次公开评估误解为只尝试过一个方法。

限制。 1.95 的二阶矩门槛依赖主任务 RMS 归一化规律；它是先验选择条件，并非对输出进行硬归一化。开发集推断谱被用于再观测模拟，日志中以其为“reference”的误差不是私有 GT 误差。对幅度和谱变化的适应性需要独立诊断验证，不能只凭 R 接近 1 或能量接近 2 宣称科学通过。

证据：solve.py；state.json；pi.txt。

5.3 Heat G2 r1：固定幂律先验的贝叶斯岭回归

方法。 在 32 模态正弦前向模型中，使用独立高斯先验 $v_k \propto k^{-2}$，并把先验总方差固定为 2。按观测噪声 sigma 加权后，直接求解带对角先验精度的 32 × 32 正规方程；线性求解异常时回退至最小二乘。输出按目标网格重建，不直接把输出能量归一化。

探索路径。 可观察记录包含环境与公共接口检查、低模态系数和能量估计、多组自定义合成数据试验、先验形状与强度比较，以及最终开发集残差检查。最初两次使用 pandas 的命令失败后改用 NumPy 读取 CSV。共 36 条 shell 命令，其中只有 1 次公开候选登记；sim.py 至 sim6.py 等脚本说明登记前后存在多轮本地试验，不能将公开评估数当作全部探索次数。

关键修改与选择。 从观测数据推断的归一化与频谱结构出发，最终固定先验幂次 2、总方差 2，使用 NumPy-only 实现，避免执行时依赖未安装包。首次合法登记在 6.80 分钟，选择 candidate-001 后主动结束；首次与最终源码相同。记录到一次正常原生压缩，没有单 token 请求。

限制。 先验总方差 2 和幂次 2 是固定的开发集推断，不随实际场幅度或谱指数自适应。R 接近 1 只说明对公开观测的拟合水平。自建合成数据与真实私有分布未必相同，幅度、谱衰减和连续缺失诊断将分别检查这些边界。

证据：solve.py；state.json；pi.txt。

5.4 Heat G3 r1：开发集谱包络与 Student-t 收缩

方法。 在 32 模态正弦前向模型中建立独立 Student-t（自由度 1）先验，用 IRLS 反复求解 32 × 32 线性系统，最多迭代 60 次。每模态先验尺度来自六例开发观测推断的固定谱包络；高斯 MAP 为初始化和异常回退，最后在给定网格重建初场。

探索路径。 可观察记录包括截断最小二乘与谱能量检查、几何谱经验贝叶斯拟合、Gaussian/Student-t 收缩比较、自己定义的合成谱与开发集谱模板再观测、先验尺度扫描。一次经验贝叶斯试验因 Cholesky 非正定失败，一次大规模合成命令在 600 秒后以 124 退出，随后改用小型充分统计量计算与较短模拟。共 28 条 shell 命令、2 次公开评估、2 个独立源码哈希；首次合法登记在 18.44 分钟。

关键修改与选择。 candidate-001 使用原先验包络；在模板试验后将全部先验尺度乘以 0.5，登记并显式选择 candidate-002。两次公开评估均生成合法输出。会话主动结束，记录到一次正常原生压缩，没有单 token 请求。

限制。 尺度包络固定在开发集推断的绝对幅度上，谱形和幅度变化可能影响收缩偏差。日志中的“reference truths”是从公开有噪观测得到的高信噪比估计及合成模板，并非私有 GT；Agent 自报的恢复误差不能当作测试精度。六例模板试验可能偏向开发集谱结构，需由独立诊断检验。

证据：solve.py；solve.py；state.json；pi.txt。

5.5 ODE G1 r1：平滑稀疏回归、多支撑选择与轨迹拟合

方法。 先用 Savitzky-Golay 平滑求导（31 点窗口、三次多项式）和序贯阈值最小二乘形成基线，联合使用公开 train 与 validation 轨迹。最终版本增加多阈值、显著性筛选和穷举子集 BIC 支撑提议，在最多 10 个非零系数约束下尝试 DOP853 灵敏度积分与加权轨迹残差拟合；数值异常时回退到平滑稀疏回归。

探索路径。 先检查六例开发数据，修正本地脚本的维度与返回值错误，再用自建合成轨迹比较支撑筛选和轨迹拟合。还进行了高噪声、边界系统及 12 例批处理规模试验。第 8.02、13.17、17.40 分钟分别登记三个独立源码版本，共 41 条可见 shell 命令、3 次公开评估、38 次成功模型请求。

关键修改与选择。 由快速平滑回归扩展到多支撑候选，调整 BIC 候选池，并为最终实现加入 95 秒软预算和异常回退。18.38 分钟时明确提交 candidate-003，主测试首次至最终提高 0.226 分；主测试执行时间中位数从 0.464 秒增至 34.785 秒。资源开销增加远大于此次精度分的改善。

限制。 合成有限差分检查发现灵敏度列序与 C.ravel() 的交错系数顺序不一致，相对差异为 1.103；正确重排列后降至 6.47e-11。此项仅为实现诊断，没有修改封存代码或重算成绩，不能单独解释实际得分。95 秒软预算只在支撑循环边界检查，不能保证中途积分及时退出。主任务和三个结构主题均通过，仍不能据此证明任意系统上的适用性。

证据：solve.py；state.json；pi.txt；sensitivity-audit.json。

5.6 ODE G2 r1：弱形式支撑搜索与联合轨迹精修

方法。 联合使用公开 train 和 validation 轨迹，建立多窗口积分弱形式回归，按观测噪声加权并对部分多项式项做噪声偏差修正。分别对两个坐标构造逐步增项和系数幅度排序路径，用 BIC 型准则及增/删/换项局部搜索选择支撑；随后用 DOP853 轨迹模拟和非线性最小二乘精修系数，最后限制总非零项数不超过 10。最终源码没有把第一坐标方程固定为 z_2。

探索路径。 从样条平滑、数值微分和稀疏回归开始，经历数组维度等本地程序错误及一条约 300 秒命令超时，转向积分弱形式；比较共享/分坐标支撑、弱残差选参和轨迹精修，再做 Duffing 与更一般合成系统试验。后一条命令约 900 秒后结束。共 24 条 shell 命令、1 次公开登记、1 个独立源码版本。

关键修改与选择。 研究期间修复噪声数组广播、权重和支撑参数打包，最终将已测试的 proto 实现导出为 solve.py。长命令结束后，在剩约 252 秒的模型调用边界出现一次合并了 10/5 分钟阈值的宿主提醒记录；于第 26.02 分钟登记 candidate-001，并显式提交后主动结束。首次与最终哈希相同。提醒发生在交付之前，但本会话不能单独证明提醒的因果作用。

限制。 弱形式窗口重叠，BIC 型准则只是选择启发式；超过 10 项时按绝对系数删项，选择不具备坐标缩放不变性。源码的噪声偏差修正覆盖 z_1^2、z_1^3、$z_1^2z_2$、$z_1z_2^2$，却未修正 z_2^2 与 z_2^3，可能影响交换坐标和新支撑系统的初始选择。后续轨迹精修能否补偿这些偏差须由私有诊断判断。局部合成命令耗时约占主要研究预算，不能将未完成试验记为已验证泛化。

证据：solve.py；state.json；pi.txt；events.jsonl。

5.7 ODE G3 r1：平滑导数初始化、振子模板与扩展支撑拟合

方法。 将 train 与 validation 联合使用，以平滑样条导数和全库最小二乘得到系数初值，再对候选支撑进行带噪声权重的 DOP853 轨迹匹配。优先尝试四项/五项阻尼三次振子模板及扩展模板，再考虑按导数回归系数排序的通用支撑路径；用拟合代价加复杂度惩罚选型，选定支撑后更严格积分精修。系数最后截去微小值并四舍五入至三位小数。

探索路径。 可观察实验包括平滑导数实现与维度修复、支撑集合比较、公开轨迹联合拟合、精度/速度检查及自行构造的非模板合成系统测试。首个本地全搜索版本在开发集约用 40 秒，随后加入模板优先和噪声水平早停策略。共 30 条 shell 命令、2 次公开登记、2 个独立源码哈希，首次合法登记为 7.63 分钟。

关键修改与选择。 candidate-001 已有模板优先与通用后备搜索；candidate-002 新增两种“模板 + 最强非模板项”的扩展支撑，各最多 10 项，在更宽搜索之前评估。最终显式选择 candidate-002。修改保留了主要拟合、早停和精修逻辑，源码差异可以直接核对。

限制。 模板优先和噪声水平早停有助于节省主任务计算，但可能使模型选择依赖开发集结构；非等比缩放也会改变按绝对系数排序的路径。通用及扩展支撑提供适应机会，却增加轨迹优化成本，需检查诊断精度与 120 秒整批限制。诊断只测试最终候选，不能据此分离新增扩展支撑的诊断收益。源码注释声称生成系数位于细小数网格，但作者生成器实际连续均匀抽样且不舍入；该假设不受生成规则支持，三位小数量化的影响需由私有误差衡量。

证据：solve.py；solve.py；state.json；pi.txt；ode.py。

5.8 Poisson G1 r1：稀疏 LU、低导入开销与算子因子缓存

方法。 对给定稀疏算子做 SuperLU 分解，优先使用 MMD_AT_PLUS_A 排序，一次求解四列 RHS，并以原 CSR 算子复核残差。通过构造最小 Python 包占位并直接导入 SciPy 的 _superlu 扩展减少启动开销；这里仍是 LU 分解，不是 Cholesky。利用任务保证的对称性将 CSR 数组作为转置等价的 CSC 输入；保留完整 SciPy 转换、迭代改进及 NumPy CG 回退分支。

探索路径。 日志记录了 49 条 shell 命令，包括比较 LU 排序、带状分解、Jacobi-CG、导入与 I/O 耗时、纯 NumPy 嵌套剖分原型，以及合成大网格。缺失工具、扩展导入与调试错误均保留。约第 10.58 分钟登记首个候选，公开评估两次、对应两个源码哈希。研究内发生三次请求层失败（一次客户端断连、两次上游传输错误），由原生重试恢复；失败请求占用约 142.4 秒，未知输出预留 49,152 token，均保留在成本中。

关键修改与选择。 candidate-001 到 candidate-002 的源码差异仅加入算子分解缓存，并将求解入口改为缓存查询。键包含维数及完整 CSR 指针、索引和数值字节，不缓存旧 RHS 的解；非零元超过 200,000 时不缓存。最终显式选择 candidate-002。其主测试分数从 65.875 到 65.449，小幅下降；两个独立计时窗口同时存在测量波动，不能将这一差值全归因于缓存。仅最终候选做了缓存诊断，因此不能据此计算缓存改动的因果收益。

限制。 直接调用 SciPy 私有扩展和替换模块导入状态依赖冻结环境；回退分支未被本批成功输出证明全部正确。源码中的 NumPy CG 回退用 searchsorted 在整条 CSR 列索引数组上找对角元，但该数组通常仅各行排序，属于静态发现的潜在缺陷，不能解释为本批已经发生的失败。正常 LU 路径通过了本批主测试与全部诊断。256 网格跳过缓存，避免大因子累积；更大或非对称系统不在本批泛化结论内。

证据：state.json；pi.txt；events.jsonl；solve.py；solve.py。

5.9 Poisson G2 r1：精确算子分组、SuperLU 与多 RHS 复用

方法。 规范化 CSR 后，对形状、indptr、indices 和数值数据共同计算 SHA-256，并再做数组精确比较，将相同算子的案例分组。每组用 SuperLU（MMD_AT_PLUS_A 排序、对称模式、优先关闭阈值主元）分解一次，将组内所有 RHS 拼接为块求解；随后检查残差，必要时做一次迭代修正。实际是稀疏 LU，不是 Cholesky 分解。

探索路径。 检查公开矩阵结构与重复算子，比较 Jacobi-CG、SuperLU 排序和填充量，单独测量 Python/NumPy/SciPy 导入开销，并尝试自建 128/256 网格。登记直接法后，又开发纯 NumPy 聚合多重网格预条件 CG，修复若干数组维度问题；本地测量后认为其较慢，最终保留已登记的直接法。共 32 条 shell 命令、1 次公开评估、1 个源码哈希，首次合法登记为 16.54 分钟。

关键修改与选择。 工作区在候选登记后曾被多重网格原型和新的直接法文本覆盖，但最终显式选择的是不可变快照 candidate-001。正式评分应使用该登记快照，不能重新复制最后的工作区文件。这展示了快照/哈希与按 ID 提交的实际必要性。

限制。 直接法在二维网格上的填充与内存会随规模增长；分组仅复用完全一致的算子，数值正确性和顺序独立性仍需私有缓存诊断确认。研究中有 7 次请求层失败（1 次上游超时、6 次传输错误），占用约 725.2 秒请求时间，另有声明退避 24 秒，均在同一 attempt 恢复。失败请求的实际输出未知，按冻结策略计入预算 114,688 token；本会话已知输出 56,183、预算计入 170,871，不能把两者混写。其研究用时受到服务波动显著影响，不能直接归因于指导强度。

证据：solve.py；state.json；pi.txt；events.jsonl。

5.10 Poisson G3 r1：带状 Cholesky 与 ctypes 直连 LAPACK

方法。 直接读取稀疏 NPZ，以自然顺序将对称算子的下三角装入带状存储。对 n ≤ 256 且带宽 ≤ 4n 的输入，调用 LAPACKE dpbtrf / dpbtrs 做带状 Cholesky 和四 RHS 求解；更大或不适合带状路径的情况回退到 SuperLU。按矩阵数组与维数的摘要缓存因子，640 MiB 缓存上限，按插入顺序淘汰；这不是会随访问更新的 LRU。

探索路径。 51 条可见 shell 命令涵盖公开基线与接口阅读、稀疏排序和带状分解比较、完整进程与导入开销、二进制符号探查、LAPACK 调用核对和合成尺度测试。缺少 nm/readelf 等工具后使用 Python 读取 ELF 符号；一次解析脚本错误被修复。约第 3.63 分钟登记 candidate-001，之后继续优化。日志还记录了 768/1024 网格的局部性能试验，但这些自造矩阵不能等同于作者的独立诊断分布。

关键修改与选择。 首个版本通过 scipy.linalg 进入带状 Cholesky；第二个版本用 ctypes 直接加载 OpenBLAS/LAPACKE，减少 SciPy 启动开销，将带状路径阈值从 n ≤ 192 改为 n ≤ 256，并将缓存上限从 768 MiB 调为 640 MiB。两次公开评估对应两个源码哈希，显式提交 candidate-002。事后主测试分数从 41.230 提高到 58.540；这是同一会话内固定候选的观察改善。EXPERIMENTS.md 在登记后写入工作区，不属于封存的 candidate-002 源码，方法判断以登记快照及日志为准。

限制。 ctypes 符号名、整数 ABI 和动态库位置依赖当前镜像。四 RHS 和对称性来自既定接口，不能外推到任意矩阵。带状因子随网格和带宽增大而增长；本批 256 网格诊断虽全部通过，但整批峰值约 583.9 MiB，高于另两组，端到端中位数约 1.308 秒。主任务的启动优化收益不能直接外推成更大网格上的优势。

证据：state.json；pi.txt；events.jsonl；solve.py；solve.py。

6. 测试集与独立诊断结果

6.1 研究关闭与候选封存

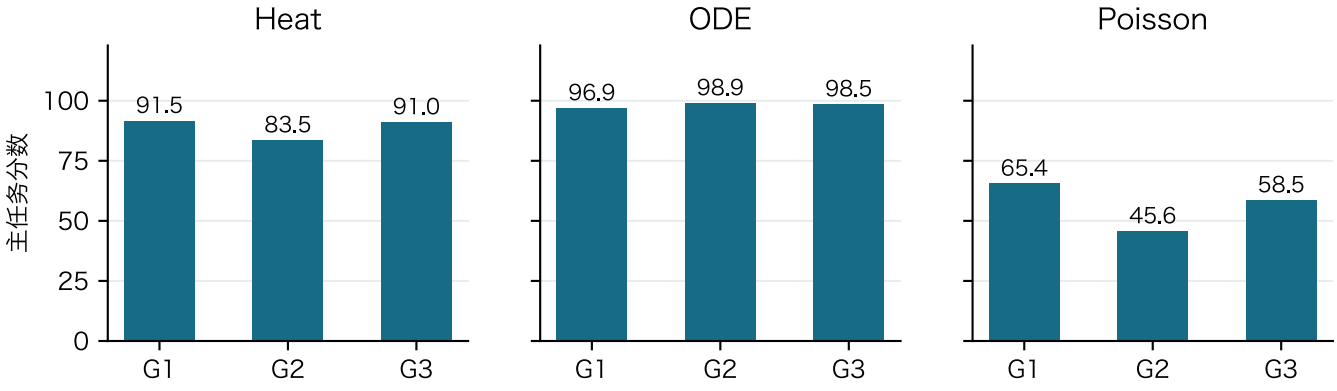
每个纳入结果表的候选均在所属研究关闭后封存，再执行对应的私有测试；各候选的关闭时间、源码哈希与评分记录已核验。研究环境只挂载公开开发数据，私有测试反馈没有发送给研究 Agent。结果表按配置列出九个最终候选，成本按全部实际研究会话统计。

首次和最终候选来自登记时的完整不可变快照；同源码哈希可以复用测试结果并标明来源。Heat / ODE 每个不同源码候选重放三次。Poisson 每个候选按 BCCBBC 执行三次基线、三次候选，以中位数之比计时。最终候选另行执行诊断测试，不重新研究、不根据测试结果重新选择。

6.2 正式主结果

会话	最终分	三次通过数（各12例）	reward	正式加速比	主结果状态
Heat G1 r1	91.543	12 / 12 / 12	1	—	有效
Heat G2 r1	83.506	12 / 12 / 12	1	—	有效
Heat G3 r1	91.016	12 / 12 / 12	1	—	有效
ODE G1 r1	96.863	12 / 12 / 12	1	—	有效
ODE G2 r1	98.939	12 / 12 / 12	1	—	有效
ODE G3 r1	98.488	12 / 12 / 12	1	—	有效
Poisson G1 r1	65.449	12 / 12 / 12	1	3.900×	有效
Poisson G2 r1	45.626	12 / 12 / 12	1	2.583×	有效
Poisson G3 r1	58.540	12 / 12 / 12	1	3.378×	有效

九组所选最终候选的主测试均为三次 12/12 通过，reward 均为 1。Poisson G2 的三次候选数值与正式时间来自同一合格 BCCBBC 记录。



图中显示九组有效主分。分面用于区分三类任务，不将其解释为同一能力量尺。

Heat 分难度误差。 每格为已执行重放中逐例指标的中位数 / 最大值；通过要求同一实例在所有观察重放通过。

组别	难度	通过 / 4	初场误差	未来场误差
G1	易	4 / 4	9.47e-03 / 2.30e-02	6.11e-04 / 7.61e-04
G1	中	4 / 4	2.88e-02 / 6.81e-02	7.49e-04 / 1.33e-03
G1	难	4 / 4	4.01e-02 / 6.97e-02	2.02e-03 / 3.54e-03
G2	易	4 / 4	3.78e-02 / 4.52e-02	6.11e-04 / 7.59e-04
G2	中	4 / 4	6.79e-02 / 8.42e-02	7.39e-04 / 1.21e-03
G2	难	4 / 4	8.10e-02 / 1.05e-01	2.03e-03 / 3.65e-03
G3	易	4 / 4	1.63e-02 / 2.51e-02	6.10e-04 / 7.60e-04
G3	中	4 / 4	2.68e-02 / 6.51e-02	7.46e-04 / 1.25e-03
G3	难	4 / 4	4.43e-02 / 7.17e-02	2.01e-03 / 3.59e-03

ODE 分难度误差。 每格为已执行重放中逐例指标的中位数 / 最大值；通过要求同一实例在所有观察重放通过。

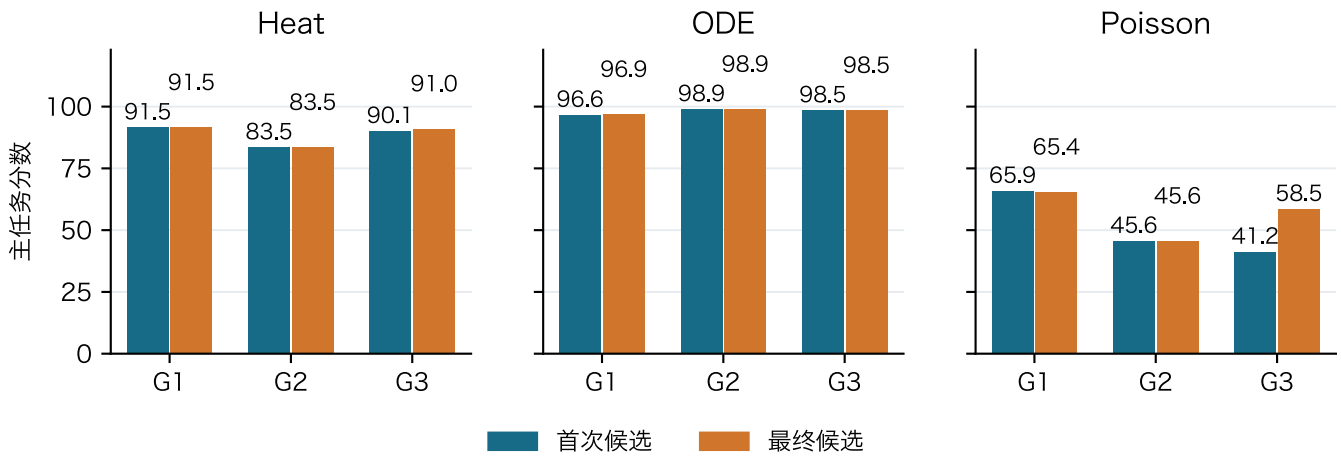
组别	难度	通过 / 4	轨迹误差	场误差
G1	易	4 / 4	6.97e-04 / 1.78e-03	8.67e-04 / 2.40e-03
G1	中	4 / 4	2.84e-03 / 3.70e-03	1.99e-03 / 2.23e-03
G1	难	4 / 4	5.19e-03 / 7.05e-03	4.91e-03 / 1.46e-02
G2	易	4 / 4	1.43e-04 / 2.27e-04	1.74e-04 / 3.10e-04
G2	中	4 / 4	8.39e-04 / 1.13e-03	5.50e-04 / 8.76e-04
G2	难	4 / 4	1.92e-03 / 3.53e-03	2.87e-03 / 3.62e-03
G3	易	4 / 4	1.20e-03 / 1.71e-03	4.09e-04 / 6.43e-04
G3	中	4 / 4	9.87e-04 / 1.43e-03	6.50e-04 / 1.18e-03
G3	难	4 / 4	2.83e-03 / 4.36e-03	3.13e-03 / 3.69e-03

Poisson 分难度误差。 每格为已执行重放中逐例指标的中位数 / 最大值；通过要求同一实例在所有观察重放通过。

组别	难度	通过 / 4	最大相对残差	最大解误差
G1	易	4 / 4	1.78e-16 / 1.84e-16	2.04e-15 / 2.26e-15
G1	中	4 / 4	1.99e-16 / 2.05e-16	3.74e-14 / 4.08e-14
G1	难	4 / 4	2.09e-16 / 2.19e-16	9.95e-13 / 1.24e-12
G2	易	4 / 4	1.85e-16 / 1.90e-16	2.15e-15 / 2.32e-15
G2	中	4 / 4	1.90e-16 / 2.01e-16	4.03e-14 / 4.65e-14
G2	难	4 / 4	2.09e-16 / 2.16e-16	9.91e-13 / 1.15e-12
G3	易	4 / 4	3.46e-16 / 3.51e-16	4.18e-15 / 4.69e-15
G3	中	4 / 4	4.92e-16 / 5.16e-16	1.40e-13 / 1.76e-13
G3	难	4 / 4	5.33e-16 / 5.46e-16	3.19e-12 / 3.78e-12

6.3 从首次候选到最终候选

会话	首次分	最终分	分差	源码复用
Heat G1 r1	91.543	91.543	0.000	candidate-001
Heat G2 r1	83.506	83.506	0.000	candidate-001
Heat G3 r1	90.088	91.016	0.928	否
ODE G1 r1	96.637	96.863	0.226	否
ODE G2 r1	98.939	98.939	0.000	candidate-001
ODE G3 r1	98.488	98.488	0.000	否
Poisson G1 r1	65.875	65.449	-0.425	否
Poisson G2 r1	45.626	45.626	0.000	candidate-001
Poisson G3 r1	41.230	58.540	17.310	否



差值是在同一会话内部、相同私有测试集上的事后描述。它不提供重新选候选的机会，也不能作为独立重复试验或因果效果估计。同哈希复用的两端不被计为两次独立算法发现。

6.4 诊断测试：数据条件变化后的行为

Heat 每主题 4 例：幅度 0.5 / 2 倍、谱衰减指数 1 / 3 各跨中高难度；连续区间缺失固定 25%，中高难度各 2 例。所有实例保持 32 模态，噪声随干净观测 RMS 缩放。

ODE 每主题 4 例，中高噪声各 2 例：非等比坐标缩放 $z = (2q_1, 0.5q_2)$、交换坐标 $z = (q_2,q_1)$、新的稳定三次系统。库、稀疏项数、时间网格与输出接口不变。

Poisson 每主题 4 例，对比度 30 / 300 各 2 例：256 × 256 大网格、128 × 128 五圆系数、128 × 128 交错重复算子与不同 RHS。缓存主题逆序是对相同四例的额外顺序检查，不能当作新增四个实例。

Heat 诊断。

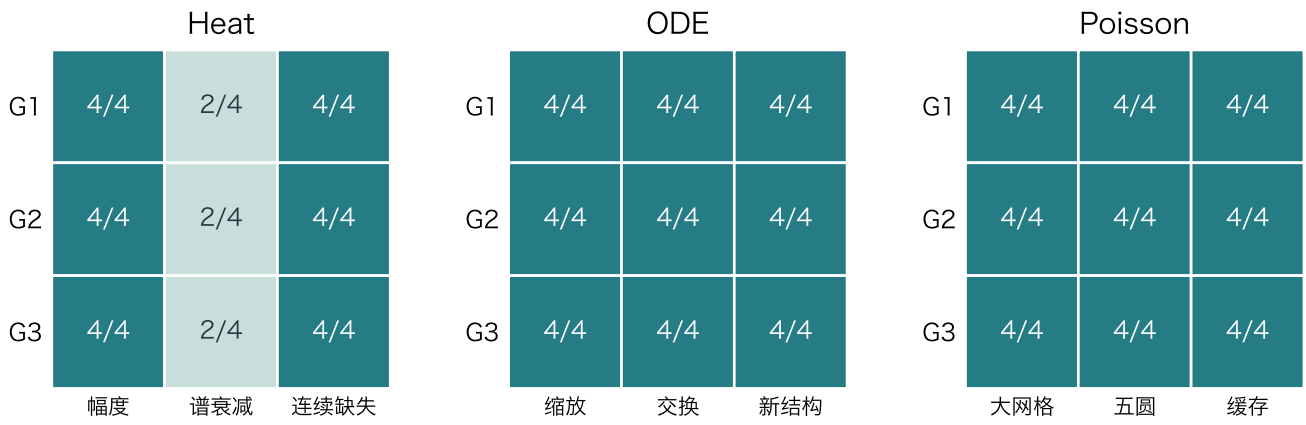
组别	主题	通过 / 4	最大初场误差	最大未来场误差
G1	幅度 0.5 / 2 倍	4 / 4	7.46e-02	2.76e-03
G1	连续缺失 25%	4 / 4	7.10e-02	2.68e-03
G1	谱衰减 1 / 3	2 / 4	3.27e-01	3.60e-03
G2	幅度 0.5 / 2 倍	4 / 4	1.32e-01	2.73e-03
G2	连续缺失 25%	4 / 4	9.19e-02	6.32e-03
G2	谱衰减 1 / 3	2 / 4	3.21e-01	3.53e-03
G3	幅度 0.5 / 2 倍	4 / 4	6.93e-02	2.78e-03
G3	连续缺失 25%	4 / 4	7.57e-02	4.40e-03
G3	谱衰减 1 / 3	2 / 4	3.27e-01	3.58e-03

ODE 诊断。

组别	主题	通过 / 4	最大轨迹误差	最大场误差
G1	非等比缩放	4 / 4	9.48e-03	1.55e-02
G1	坐标交换	4 / 4	6.45e-03	7.70e-03
G1	稳定三次系统	4 / 4	1.23e-02	2.48e-02
G2	非等比缩放	4 / 4	2.76e-03	5.45e-04
G2	坐标交换	4 / 4	1.68e-03	2.89e-03
G2	稳定三次系统	4 / 4	1.84e-03	3.99e-03
G3	非等比缩放	4 / 4	1.53e-02	5.52e-04
G3	坐标交换	4 / 4	3.05e-03	6.62e-03
G3	稳定三次系统	4 / 4	2.44e-03	6.98e-03

Poisson 诊断。

组别	主题	通过 / 4	最大相对残差	最大解误差
G1	交错算子 / RHS	4 / 4	2.07e-16	1.12e-12
G1	五圆系数	4 / 4	2.13e-16	7.14e-13
G1	256 × 256 网格	4 / 4	2.28e-16	1.83e-12
G2	交错算子 / RHS	4 / 4	2.07e-16	1.15e-12
G2	五圆系数	4 / 4	2.09e-16	7.10e-13
G2	256 × 256 网格	4 / 4	2.27e-16	1.89e-12
G3	交错算子 / RHS	4 / 4	5.32e-16	1.26e-12
G3	五圆系数	4 / 4	5.54e-16	4.29e-12
G3	256 × 256 网格	4 / 4	7.53e-16	8.99e-12



图内分母均为每主题 4 个实例。Heat 的失败集中在谱衰减主题；ODE 与 Poisson 三组各主题均通过。Poisson 图中为正序，逆序结果另列表报告。

组别	顺序	通过 / 4	最大解误差	正式加速比	计时状态
G1	正序	4 / 4	1.12e-12	4.207	有效
G1	逆序	4 / 4	1.12e-12	4.249	有效
G2	正序	4 / 4	1.15e-12	2.559	有效
G2	逆序	4 / 4	1.15e-12	2.563	有效
G3	正序	4 / 4	1.26e-12	3.804	有效
G3	逆序	4 / 4	1.26e-12	3.797	有效

对全部三个组、四个缓存实例和三次 C 重放逐一检查，正序与逆序的同一实例输出文件逐字节相同，共 36 对。缓存顺序与宿主观察审计

6.5 资源、计时与失败实例

主任务最终候选	端到端秒（中位数）	CPU 秒（中位数）	峰值 MiB（最大）	实际测量尝试
Heat G1 r1	0.269	0.397	30.7	不适用
Heat G2 r1	0.227	0.379	30.8	不适用
Heat G3 r1	0.225	0.371	30.8	不适用
ODE G1 r1	34.785	34.560	72.6	不适用
ODE G2 r1	13.965	13.968	60.4	不适用
ODE G3 r1	42.785	42.679	60.2	不适用
Poisson G1 r1	0.290	0.371	86.2	2
Poisson G2 r1	0.440	0.523	93.2	1
Poisson G3 r1	0.333	0.406	115.2	1

Poisson 各行采用所选合格窗口中的三次候选重放。CPU 与墙钟测量范围不同，不能用两列相除反推候选的并行度。

Heat 诊断资源。

组别	执行范围	端到端秒	CPU 秒	峰值 MiB	加速比
G1	诊断 12 例整批	0.204	0.292	30.4	—
G2	诊断 12 例整批	0.164	0.264	30.6	—
G3	诊断 12 例整批	0.171	0.261	30.3	—

ODE 诊断资源。

组别	执行范围	端到端秒	CPU 秒	峰值 MiB	加速比
G1	诊断 12 例整批	38.798	38.480	72.9	—
G2	诊断 12 例整批	12.619	12.648	60.7	—
G3	诊断 12 例整批	48.015	47.845	60.1	—

Poisson 诊断资源。

组别	执行范围	端到端秒	CPU 秒	峰值 MiB	加速比
G1	交错算子 / RHS	0.213	0.319	59.9	4.207
G1	交错算子 / RHS（逆）	0.211	0.316	60.1	4.249
G1	五圆系数	0.244	0.347	77.8	3.947
G1	256 × 256 网格	0.683	0.753	118.9	6.710
G2	交错算子 / RHS	0.351	0.451	78.0	2.559
G2	交错算子 / RHS（逆）	0.349	0.450	77.9	2.563
G2	五圆系数	0.384	0.487	81.3	2.527
G2	256 × 256 网格	0.897	0.967	191.2	5.126
G3	交错算子 / RHS	0.236	0.337	71.0	3.804
G3	交错算子 / RHS（逆）	0.235	0.334	70.7	3.797
G3	五圆系数	0.278	0.379	105.1	3.480
G3	256 × 256 网格	1.308	1.369	583.9	3.530

端到端时间包含进程启动、导入、I/O 和求解。CPU 与峰值内存来自可信执行器，候选自报的内部阶段时间不参与正式加速比。Heat / ODE 诊断资源值对应 12 例整批，不能将同一个整批值当成各主题独立耗时。Poisson 诊断按主题分别计时。

九组主任务均通过各自的科学与效率门槛。诊断失败实例仍完整保留在逐例结果中。

Heat 的诊断失败发生在初场恢复质量上。 三组均在谱衰减指数为 1 的中、高难度两例上未通过初场误差门槛，主题最大初场误差约 0.321-0.327，但未来场最大误差仍低于 0.004。扩散后的良好拟合可能掩盖高频恢复不足。指数为 3 的两例、幅度和连续缺失主题均通过。

实现检查与科学通过分别解释。 ODE G1 虽通过全部主测试和诊断，灵敏度列序检查仍发现缺陷，且最终候选只获得有限分数收益。通过有限样本不能替代实现正确性检查；没有将实现风险擅自改判为科学失败。

计时使用合格观测。 Poisson 三组正式结果均来自满足冻结条件的 BCCBBC 记录。拒绝窗口和请求层失败保留在执行证据中；所有有效窗口均有完整宿主观测覆盖，不选择最快重放。

诊断失败实例。 同一数据由三组共享，因此重复 ID 表示不同候选在同一实例上的结果。

会话	主题	实例 ID	误差
Heat G1 r1	谱衰减 1 / 3	6f5b711df1b95d91d9b1	E_forward=7.54e-04, E_init=2.33e-01
Heat G1 r1	谱衰减 1 / 3	0bdb0aeb8c526c94318f	E_forward=1.27e-03, E_init=3.27e-01
Heat G2 r1	谱衰减 1 / 3	6f5b711df1b95d91d9b1	E_forward=7.52e-04, E_init=2.23e-01
Heat G2 r1	谱衰减 1 / 3	0bdb0aeb8c526c94318f	E_forward=1.24e-03, E_init=3.21e-01
Heat G3 r1	谱衰减 1 / 3	6f5b711df1b95d91d9b1	E_forward=7.63e-04, E_init=2.35e-01
Heat G3 r1	谱衰减 1 / 3	0bdb0aeb8c526c94318f	E_forward=1.30e-03, E_init=3.27e-01

逐例误差、通过判定、重放序号、资源与失败原因保留在 机器可读分析、逐例 JSON 和 逐例 CSV。

7. 结论

交付能力。 九组配置均有封存的可执行候选，首次合法登记约 3.63-26.02 分钟。全部 10 个研究会话实际占用 166.87 分钟，宿主 attempt 墙钟合计 176.88 分钟；后一指标包含启动与收尾，不含后续评分等待。已知输出 575,944 token，预算计入 739,784 token；预算计入量不等于服务商账单。

科学质量。 九个最终候选主测试均三次 12/12 通过，九组 reward 均为 1。Heat 分数为 91.543、83.506、91.016；ODE 为 96.863、98.939、98.488；Poisson 正式加速比分别为 3.900、2.583、3.378 倍。不同任务分数不能合并为统一能力量尺。

探索收益。 Heat G3 首次至最终提高 0.928 分，ODE G1 提高 0.226 分，Poisson G3 提高 17.310 分。ODE G1 的时间开销明显上升，表明更多复杂拟合未必划算。Poisson G1 下降 0.425 分，不能据此区分算法收益与计时波动；ODE G3 两个不同源码版本的主测试指标相同。公开评估次数不能代表全部探索量。

适应能力。 Heat 三组诊断均为 10/12，共同边界在慢谱衰减主题。ODE 三组均为 12/12；Poisson 三组均通过各主题及缓存逆序检查。36 对已保存的正逆序缓存输出逐字节相同；这只覆盖本批两个算子及四组 RHS 的排列，不证明任意缓存序列安全。

本报告的九组配置用于案例分析，结论适用于这些任务、模型路由、预算与数据。三次重放检验可执行性和计时稳定性，12 个测试实例刻画实例分布，均不增加 Agent 样本数。本文不报告提示组别显著性排名。

8. 问题分析与后续改进

8.1 交付效率与执行保障

保留自主探索和硬截止，将长命令改为可轮询作业，提供剩余预算状态，并在共同说明中解释长阻塞可能延迟提醒。全部执行记录包含一次 ODE G1 未登记候选的会话；九组结果表对应各组选定的最终候选，不能据此宣称所有启动都在首次研究中交付成功。成本表保留全部会话用量。

选定会话每组登记 1-3 个源码版本，20 次公开评估额度并非主要瓶颈。优先降低本地调试与反馈等待成本，避免先增加评估额度。ODE G1 已提供可运行基线，但复杂拟合增益很小，应结合精度与资源开销决定是否继续迭代。

8.2 科学指标与方法边界

Heat 应同时关注可辨识模态、先验敏感性和初场不确定性；观测残差与未来场误差容易遗漏高频偏差。可在统一开发工具中加入合成压力试验，检验幅度与谱先验的适应性。本批没有证明某一种修正必然解决慢谱衰减问题。

ODE 应保留轨迹和向量场双指标，明确 train/validation 都是开发数据。G1 的解析雅可比必须先与有限差分核对；G2 的噪声修正不覆盖所有坐标幂次，G3 的系数取整依据与真实连续分布不符，均需针对性检查。三个方法在本批结构诊断均通过，不能把源码风险直接写成已发生的测试失败。

Poisson 应分开报告完整进程性能与求解阶段解释。G1/G3 减少导入开销，但私有扩展和 ctypes 接口降低依赖可移植性；G2 的标准 SuperLU 接口更直接，网格扩大后的填充与内存仍需评估。启动优化与分解规模效应应分别分析。

8.3 计时与实验设计

正式性能测量应使用专用、可控的宿主，保持固定 BCCBBC 顺序、预先声明的尝试上限、首次有效选择和全部拒绝记录。数值正确性与计时资格分开记录，不能把环境无效改写为算法零分或选择最快时刻。

下一版观察器可事先将异常采样间隙纳入拒绝规则，并保存单调时钟与墙钟对照。当前策略禁止新 swap-out，将无法归因的全局 swap-in 作为诊断；候选容器自身禁止 swap，两者须清楚区分。

本报告是九组配置的案例分析。执行次数和候选选择过程并非均衡重复设计，因此不做指导强度的显著性排名。若研究普遍效果，需另行预注册独立会话与随机化区组；增加计时次数和测试实例不能替代独立 Agent 样本。

8.4 审计范围与证据限制

宿主记录能够确认候选登记、哈希、公开评估、最终选择、研究关闭、用量与测试执行；原生工具事件和源码共同支持方法分析。工具输出有截断可能，工作区中的说明也不能证明所有未记录实验。内部推理和日志外活动不作为可核验的实验事实。

模型版本只取得服务商声明与请求/响应可观察信息；固定随机种子不等于模型生成确定性。主任务与诊断仍然是有限的合成分布，诊断通过不代表任意分布泛化。少量主题实例和每组单个选定结果用于发现具体失效机制，不支持总体概率估计。

冻结清单、数据与 GT 校验、执行器验收、探索时间线和逐例结果构成可复核证据链。九组配置对应十个实际研究会话，ODE G1 采用最后一个独立会话封存的 candidate-003；此前一次会话没有登记候选，其 30 分钟和 18,327 输出 token 保留在总成本中。选择过程不构成均衡随机重复设计。报告构建不触发任何新模型研究或候选执行。主结果及诊断使用同一最终快照，图表数字来自机器可读分析。

证据	文件
冻结运行计划	plan
探索时间线	timeline
封存后的原始结果	results
汇总与成本	analysis
方法证据与判断	methods
数据与 GT 检查	GT QC
服务恢复	restoration

PDF 使用可选择文本、嵌入 TrueType 字体和 SVG 矢量图；逐页渲染检查与字体/文本检查记录随报告交付。