SciResearch-Bench-Lite：科学计算自主研究基准设计与实验报告

课程作业最终报告 · thinking/max 专版 · 2026 年 10 月 25 日
研究领域：科学计算；提交形式：个人 GitHub 仓库。
提交仓库 · 阅读打印版 PDF · 离线阅读版 HTML · 完整材料与 Release

摘要与阅读说明

本项目关心一个具体问题：**AI 能否在有限时间和工具预算内，把科研任务转化为可运行的方法，并利用实验反馈改进结果？** 为此，在科学计算领域实现了三条任务：从温度观测恢复初始温度分布（Heat）、从带噪运动轨迹识别动力学方程（ODE）、在保证解正确的前提下加快稀疏方程求解（Poisson）。三条任务共生成 90 个合成实例，配置了 11 种作者基线，并由独立程序验证候选代码的输出。

本报告只展示 **thinking=enabled、effort=max** 条件下的 15 个研究会话，每会话最多 20 万输出 token、30 分钟和 20 次公开评估。15/15 形成通过公开产物检查的提交；14/15 取得有效且成功的最终成绩。剩余 Poisson G2 已通过数值检查，但正式计时窗口不合格，正式分数留空；独立补测的原始耗时比为 **2.488×，仅作诊断**。本批 11 种作者基线中，10 项取得有效结果，Jacobi-CG 的独立基线窗口被拒绝；三条任务均有有效基线验证。

这些结果表明，项目已形成“任务—数据—Agent 实验—可信提交—独立评分—日志分析”的可运行闭环。会话内迭代既有改进也有退化，执行器故障和宿主计时干扰也会影响结果。中途修复、已使用过的隐藏集及小样本限制了结论，不能据此宣称 thinking 的因果收益或真正的递归自我改进。

版本范围： 上一版跨批比较报告、图表、数据和生成脚本已完整暂存，原 Release 附件保留。本版主表、图表、用量、基线与端到端案例均取自 thinking 批次；历史文档不参与本版统计。

读表约定： 分数保留三位小数；`0` 是按规则得到的零分，`—` 是没有有效成绩，两者不同。`reward=1` 表示满足该任务全部成功条件，`reward=0` 表示有效评测下未成功。主表按 **Heat → ODE → Poisson、G1 → G2 → G3、r1 → r2 → r3** 排列，实际执行序号另列。完整精度和来源哈希见整理后的数据。

1. 背景与研究目标

普通问答往往只检查最终答案；科研工作还要求选择方法、实现代码、设计实验、识别失败并修改方案。一个程序能运行，不一定得到了正确科学结果；一次公开测试表现好，也不一定能推广到新的测试样本。因此，Auto Research Benchmark 需要同时评价研究过程与最终产物。

本报告采用以下工作定义：Auto Research 指让 Agent 自主完成方法选择、实验和改进；AI Scientist 的范围可以进一步包括提出想法、文献分析、写作与评审；Research Agent 是执行这些工作流的工具使用系统。RSI（Recursive Self-Improvement，递归自我改进）则要求系统修改自身的策略、工具或代码，并验证改进能作用于后续任务。**本项目测量的是 Agent 对当前求解器的研究与改进，没有把模型或 Agent 自身作为优化对象。**

选择科学计算有三个原因：第一，热方程、常微分方程和线性系统都有明确数学结构；第二，可以生成数据并独立构造参考真值；第三，任务规模适合个人机器运行。代价是实验主要代表受控合成问题，不能直接外推到实验室发现或开放世界科研。

项目围绕四个问题组织：

1. 三条任务是否具有完整的数据、环境、基线和独立自动评分?
2. 给予不同强度的方法指导后，Agent 能否形成有效提交?
3. 同一会话首次与最终候选相比，是否出现可核验的改进或退化?
4. 数值正确性、计算效率、资源开销与执行可靠性之间有什么关系?

后文"是否符合预期"是依据任务机制的事后分析，不冒充预注册的统计假设检验。本报告不比较开启与关闭 thinking 的效果。

2. 相关工作调研与设计借鉴

下表比较了六项相关工作。前四项依据论文，后两项同时依据本地固定版本的官方源码。详细源码位置、工作流图与版本说明见调研文档。

工作	任务、环境与工具	评价方式	本项目借鉴及局限
AI Scientist-v2	提出假设，管理机器学习实验，执行代码并撰写论文；使用实验管理与树搜索	实验指标、图文检查和论文评审	借鉴"假设—实验—分析—修订"；论文质量与数值正确性不能用同一指标概括
ScienceAgentBench	从科研论文抽取数据分析任务，要求生成可执行 Python 程序	检查程序、运行产物与成本	借鉴可执行产物验收；完成指定分析不等于提出原创科学理论
MLGym	可执行的机器学习研究环境，支持方法实现、训练、实验及反馈迭代	任务性能指标及实验轨迹	借鉴公开反馈驱动的迭代；跨任务指标与计算预算需要分别校准
Darwin Gödel Machine	修改 Agent 自身代码，并保留不同后继版本	使用编程基准实测改动效果	帮助界定 RSI；编程能力提升不能自动等同于科学研究能力提升
ASI-Bench	在同一科研项目中改变方法指导信息，Agent 选择方法并调用工具	产物合法性门槛、任务评分、运行与评价状态	借鉴匹配的信息条件；本项目 G2 只给方向，不完全复刻其 B2 方法提示
Terminal-Bench-Science	专家设计的终端科研工作流；任务包包含指令、环境、测试和参考解	独立任务测试，并通过参考解、空操作和对抗检查维护质量	借鉴任务包、隔离执行和客观验收；真实任务的依赖维护与专家制作成本较高

两项主要参考各解决了一类问题：ASI-Bench 启发我们在保持任务目标和评分一致时，改变给 Agent 的方法指导；Terminal-Bench-Science 启发我们把题目做成真正可运行、可测试、可复查的任务包。本项目将两者结合，用三种指导强度研究同一数值任务，并将结果交给独立判题程序。

现有工作的共同挑战包括：任务和环境差异会干扰模型比较，最终分数难以解释过程失败，公开反馈可能被过拟合，以及真实科研的新颖性很难完全自动评分。本项目通过统一接口、固定预算、隐藏测试和细分失败状态降低这些问题，但并未解决全部开放科研评价难题。

3. Benchmark 任务与数据构建

3.1 三条任务分别考察什么

任务	通俗解释与研究难点	输入	必须提交的产物
T1 / Heat：热方程初场恢复	热量扩散会抹平细节；根据较晚、带噪、缺失的温度观测推回最初分布，需要防止噪声被放大	时空温度观测、扩散系数、256 点目标网格	每例一个 `u0.npy` 初场数组
T2 / ODE：稀疏动力学辨识	从多个初始状态的带噪轨迹中找出运动方程；既要拟合观测，又要用少量项预测新轨迹	6 条训练轨迹、2 条公开验证轨迹、时间和精确初值	一个 `(10,2)` 多项式系数矩阵 `model.json`
T3 / Poisson：稀疏求解优化	求解 `A U = B`；矩阵很大但多数元素为零，四个右端项可共享计算，要求既正确又快	稀疏矩阵 `A.npz`、四列右端项 `rhs.npy`	每例一个 `(n*n,4)` 的 `solution.npy`

三条任务使用统一候选入口：`python solve.py --input /input --output /output --seed 0`。Agent 可以读写研究工作区、调用终端、编写和运行 Python、进行局部试验并调用公开评估工具。它提交相对源码目录，由宿主复制为只读候选快照；最终提交必须引用已登记候选，不能由 Agent 自报一个分数代替程序产物。

3.2 数据来源、划分与清洗

数据来自明确的数学模型，属于**合成数据**，不是外部实测数据采集。每条任务生成 30 例，共 90 例；本轮在冻结后的固定数据划分上运行。

划分	每任务数量	三任务合计	易 / 中 / 难数量（每任务）	用途和可见范围
public-dev	6	18	2 / 2 / 2	Agent 研究时可见，获得有限的公开诊断反馈
author-calibration	12	36	4 / 4 / 4	作者基线和评测规则验收，研究 Agent 不可见
final-test	12	36	4 / 4 / 4	研究关闭后的独立最终评价，研究 Agent 不可见
合计	30	90	10 / 10 / 10	三种角色的数据彼此分开

Heat 用 32 个正弦模态构造初场，按热方程产生后续观测，再加入缺测和高斯噪声；难度随观测延迟、缺失和噪声改变。ODE 生成二维三阶多项式系统的多初值轨迹，并按通道幅度加噪；难点在于噪声导数、稀疏结构及长时预测。Poisson 构造正系数离散扩散矩阵及四列制造解，设 `B=A U*`；三个档位使用网格边长 32/64/128 和系数对比度 1/30/300。

“清洗”在这里指生成后的质量检查（QC）：数值是否有限、形状与参数是否合法、是否出现非预期重复、真值能否被独立方法交叉验证、文件是否完整。Heat 用独立传播方式和方程残差核对；ODE 用另一种积分器交叉核对；Poisson 检查矩阵性质及独立通量复算。**90/90 例通过 QC；没有根据 Agent 得分删掉困难样本。** 随机流由命名空间和根熵派生，文件保留 SHA256 以检查一致性。

仓库包含 18 例公开输入；完整 90 例输入、作者真值、QC 和生成记录在 Release 的 `author-data-v0.3.tar.gz`。详见数据索引、任务卡与逐文件清单。完整作者数据发布用于复核，但未来研究运行仍必须隔离真值；公开后的旧隐藏集不能继续被宣称为全新盲测集。

4. 实验设计与编号说明

4.1 G1、G2、G3 是指导强度

编号	提供给 Agent 的信息	本项目想观察的能力
G1	共同任务契约，加详细方法指导	能否把较明确的方法实现并完成实验
G2	共同任务契约，加研究方向；不提供具体算法名	能否从方向构建具体可行方案
G3	共同任务契约：目标、输入、工具、产物和约束	能否自主选择方法并验证结果

组别改变的是方法提示；输入、工具、预算、输出格式和科学成功条件保持一致。G3 仍有完整任务说明，并非没有任何信息。

4.2 r1、r2、r3 是什么

r 是 repeat（重复运行）的缩写。 例如，`Heat G2 r3` 表示“热方程任务、G2 方向指导组、第 3 次独立研究会话”。每次从新的研究工作区开始，不继承同组上一次的候选。重复运行用于观察同一条件下表现是否稳定。

必须区分以下三种“重复”：

标记或操作	含义	是否增加独立研究样本
r1 / r2 / r3	同一任务和指导组的第 1 / 2 / 3 个研究会话	是；但仍共享任务数据、模型和宿主条件，不代表独立数据集
a001 / a002	同一研究会话的执行尝试；a002 是明确关联的基础设施恢复重试	否；失败记录与开销另存，不把两次尝试算成两个科学样本
同一候选评分重放三次	提交后的程序在隔离环境重复执行，核对数值和运行表现	否；重复使用同一组 12 个测试实例，不变成 36 个独立测试例

`r2` 不是中等难度，`r3` 不是最终改进版，也不代表换了隐藏测试集。本轮求解器种子固定为 0；研究会话独立启动并不意味着拥有三个不同的数学数据种子。`first` 是可信登记中确定的首次候选，`final` 是会话最终指定候选；final 不是事后挑选隐藏成绩最高的版本。

4.3 为什么共有 15 个会话

任务	G1	G2	G3	会话数
Heat	r1、r2、r3	r1、r2、r3	r1、r2、r3	9
ODE	r1	r1	r1	3
Poisson	r1	r1	r1	3
合计				15

这是小规模、非均匀重复的设计：只对 Heat 每组重复三次，ODE 和 Poisson 每组只有一次，不能据此比较稳定的组间优劣。本版只统计这 15 个“任务 × 指导组 × repeat”格子；关联重试不额外增加样本数。

4.4 模型与冻结预算

项目	本轮 thinking/max 设置
研究框架	Harbor / 原生 Pi；执行期间发生三次基础设施修复，见第 9 节
模型路由	`deepseek-flash`；冻结时记录为 DeepSeek-V4.1-Flash-1017，不能独立锁定供应商内部修订
thinking / effort	enabled / max，由可信 relay 强制执行
temperature / top_p	thinking 模式 temperature 不生效，记录 null；top_p=1
单请求输出上限	4,096 token
每会话累计输出上限	200,000 token，包含 thinking、普通输出及原生压缩
每会话其他上限	1,800 秒；20 次公开评估，任一预算先到则停止
科学参数	数据、提示、顺序、评分、种子及研究资源按冻结计划执行

冻结计划的 SHA256 为 `25c3250f8615aa5a90a24206964533085b5448f06910f7e42a969e2f66763f0e`。基础设施修复通过独立、哈希绑定的附录记录，没有提高请求或会话预算。本轮为事后追加的实验，沿用已使用过的隐藏集，不能称为全新盲测；当前报告只描述本轮表现，不估计 thinking 单独带来的收益。

5. 运行环境、评测规则与隔离

5.1 从研究到评分的执行流程

1. **生成并冻结数据**：作者构造输入、参考真值和 QC，分开公开与隐藏部分。
2. **Agent 开展研究**：研究容器只能读取公开数据，编写候选并获得公开反馈。
3. **可信提交登记**：宿主对源码生成只读快照，记录候选 ID 与哈希。
4. **关闭研究**：本批全部研究关闭后，才开放最终隐藏评分；评分结果不会回灌仍在进行的研究。
5. **独立执行与判题**：全新 W 容器运行候选；J 容器读取数值产物及真值完成判断。
6. **保留全链证据**：记录分数、成功标记、资源与用量、候选版本、错误及原始日志。

实际环境为 M4 MacBook Air 上的 Colima Linux aarch64。研究容器 R 为 4 vCPU / 4 GiB；候选容器 W 为 1 vCPU / 4 GiB、单数值线程、无网络且禁 swap。数值环境固定 Python 3.12.12、NumPy 2.2.6 和 SciPy 1.15.3，镜像与源码哈希均留档。W 不接触真值和 Judge 代码；J 不运行候选源码，只检查产物。模型凭据由研究容器外的 relay 管理。

这一区分很关键：Agent 可以声称“已经正确”，但最终成绩来自独立程序对文件的检查。详见隔离协议和复现指南。

5.2 正确性、研究效果、效率与可复现性

维度	本项目如何测量	读数含义
正确性	文件格式、形状、有限数；隐藏数值误差和科学约束	程序是否交付了符合任务要求的结果
研究效果	任务连续分数；全例成功的 reward；first → final 差异	结果质量及会话内迭代是否改善
实验效率	输出 token、墙钟时间、公开评估次数；Poisson 完整批次速度	为获得产物付出了多少资源，求解器是否够快
可复现性	数据/源码/镜像哈希、冻结配置、候选快照、独立重放与日志	他人能否定位同一材料并重复核验；速度仍需新环境验收

5.3 三条任务的成功条件和分数

任务	单例科学门槛	全会话成功条件
Heat	初场相对误差 ≤0.15，未来场误差 ≤0.03	12 个 final-test 实例全部通过
ODE	阈值化后非零系数 K≤10；四条隐藏长轨迹的最大相对误差 ≤0.05，隐藏向量场误差 ≤0.05	12 例全部通过，且产物、积分及结构约束合法
Poisson	每列真实相对残差 ≤1e-8、解误差 ≤1e-5，资源合格	12 例均正确，并在合格计时窗口中达到 ≥1.5× 的批次加速

连续分数用于比较“离正确或高效还有多远”，reward 用于判断“是否完全达到门槛”，两者分别报告。设 `c(x)=min(1,max(0,x))`，有效单例/批次的核心评分式为：

- **Heat：** `100 × [0.8 c(1−E初场/0.30) + 0.2 c(1−E未来/0.06)]`。
- **ODE：** `100 × [0.5 c(1−E轨迹/0.10) + 0.5 c(1−E向量场/0.10)]`；产物、积分或稀疏约束失败按规则归零。
- **Poisson：** 在正确且正式计时有效时，`100 × c(log(speedup)/log(8))`，`speedup=三次基线耗时中位数/三次候选耗时中位数`。

Heat/ODE 按冻结规则汇总全部实例，并对候选独立重放三次。Poisson 将固定 Jacobi-CG 基线 B 与候选 C 按 **B、C、C、B、B、C** 交错运行，每批使用新容器；计入 Python 启动、导入、I/O、矩阵转换、分解及四个右端项求解，不采用候选自己打印的内部耗时。不同任务的分数含义不同，本报告不计算跨任务总平均分。

5.4 为什么必须区分零分和无效

正常无提交和科学失败可按冻结协议记零；基础设施错误或计时环境不合格缺少有效评价依据，应保留为空。Poisson 的宿主观察采用事前冻结规则：每 2 秒采样，先通过 30 秒准入窗口，测量期间继续观察，无新的 swap-out，且无超过 5% 单核占用的无关进程。轻微超限也必须保留拒绝记录，不能在看过成绩后改变门槛。

这不意味着数值正确性记录毫无价值。G2 的数值检查与原始耗时仍可以报告，但应与“正式性能成绩”分列，见第 7.4 节。

6. 作者基线：任务是否可解、评分是否有区分度

作者基线是人工预先实现的参考方法，不是额外 Agent 会话。下表只使用 thinking 批次研究全部关闭后产生的作者基线记录。11 种方法中，**10 项完成有效评分，1 项 Jacobi-CG 在独立基线计时前被准入检查拒绝**；拒绝项留空，不能称为全部 11 项评测成功。Heat、ODE、Poisson 分别有 5、3、2 项有效基线，因此"全部三条任务完成基线验证"已满足。

任务	作者方法及直观含义	分数	正确例 / 12	reward	正式加速比
Heat	未正则化 LS：直接拟合全部模态	19.556	0	0	—
Heat	rank5：只保留五个低频模态	89.893	12	1	—
Heat	Tikhonov：限制不稳定解（固定参考）	93.271	12	1	—
Heat	discrepancy：按噪声水平选正则强度	91.651	12	1	—
Heat	TSVD：截去不稳定的奇异方向	92.192	12	1	—
ODE	原始差分：直接从噪声轨迹估导数	0.000	0	0	—
ODE	固定去噪和稀疏回归（固定参考）	95.389	12	1	—
ODE	搜索去噪与稀疏参数	95.647	12	1	—
Poisson	CG：未预条件的共轭梯度	0.000	12	0	0.201×
Poisson	Jacobi-CG：对角预条件共轭梯度	—	—	—	—
Poisson	LU：一次分解复用四个右端项（固定参考）	38.758	12	1	2.239×

分数低或 reward=0 不一定是实验执行失败。Heat 直接拟合与 ODE 原始差分均不能通过全部科学检查，说明噪声放大确实形成难度；正则化和去噪方法取得较高分。Poisson CG 虽然解对 12/12 例，但只有约 0.201× 基线速度，正式分数为零；LU 为约 2.239×，通过效率门槛。

这里有两个不同角色：Jacobi-CG 作为"待评价作者方法"的独立窗口被拒绝；作为其他获准 Poisson BCCBBC 窗口中的计时基准 B，仍有对应的三次运行证据。不能用 B 的存在填补被拒绝的独立基线成绩。基线原始结果索引逐项列出结果或准入拒绝。

7. Thinking/max Agent 实验结果

7.1 总体结果

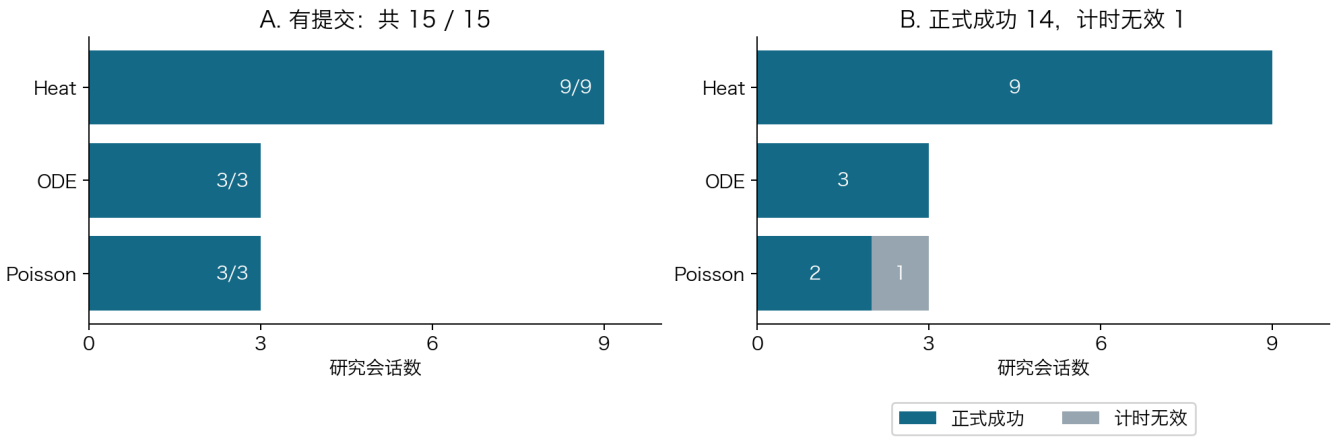


图 1。 左图统计通过公开产物检查的提交；右图统计正式最终结局。Heat 为 9 个会话，ODE 与 Poisson 各为 3 个，不能只按柱长比较任务能力。Poisson 的 1 项计时无效单列，不计为科学零分。

指标	thinking/max 本轮结果
计划研究会话	15
有提交	15 / 15（100%）
有效最终评分	14 / 15
成功，reward=1	14 / 15（93.3%）
有效但未成功	0
计时无效	1

成功比例以全部 15 个计划会话为分母。不能将“14 个有效评分全部成功”写成“15 个任务全部成功”。本轮最终候选数值检查均通过 12/12，Poisson G2 缺少的是合格性能证据。

7.2 按任务、指导组和重复次数排列的完整成绩

下表只列 thinking/max。Poisson G1 采用后续获准的独立计时补测，原拒绝记录保留；G2 的正式分数、reward 和正式加速比均留空。每行对应证据索引的同一编号，可定位研究日志、候选登记、源码及评分。

序号	会话	最终分	数值通过	reward	正式加速比	结局
01	Heat G1 r1	93.388	12 / 12	1	—	成功
02	Heat G1 r2	93.627	12 / 12	1	—	成功
03	Heat G1 r3	91.957	12 / 12	1	—	成功
04	Heat G2 r1	93.328	12 / 12	1	—	成功
05	Heat G2 r2	93.637	12 / 12	1	—	成功
06	Heat G2 r3	93.688	12 / 12	1	—	成功
07	Heat G3 r1	93.041	12 / 12	1	—	成功
08	Heat G3 r2	93.625	12 / 12	1	—	成功
09	Heat G3 r3	93.424	12 / 12	1	—	成功
10	ODE G1 r1	99.266	12 / 12	1	—	成功
11	ODE G2 r1	99.266	12 / 12	1	—	成功
12	ODE G3 r1	98.994	12 / 12	1	—	成功
13	Poisson G1 r1	68.376	12 / 12	1	4.145×	成功（独立计时补测）
14	Poisson G2 r1	—	12 / 12	—	—	计时无效；非零分
15	Poisson G3 r1	44.169	12 / 12	1	2.505×	成功

Heat 九次最终成绩为 91.957–93.688；ODE 三次为 98.994–99.266。Heat G1/G2/G3 的中位分分别为 93.388 / 93.637 / 93.424，彼此接近；每组只有三次，不能把这个排序当作指导组稳定优劣。ODE 与 Poisson 每组仅一次，更不宜作显著性结论。

7.3 会话内迭代与资源

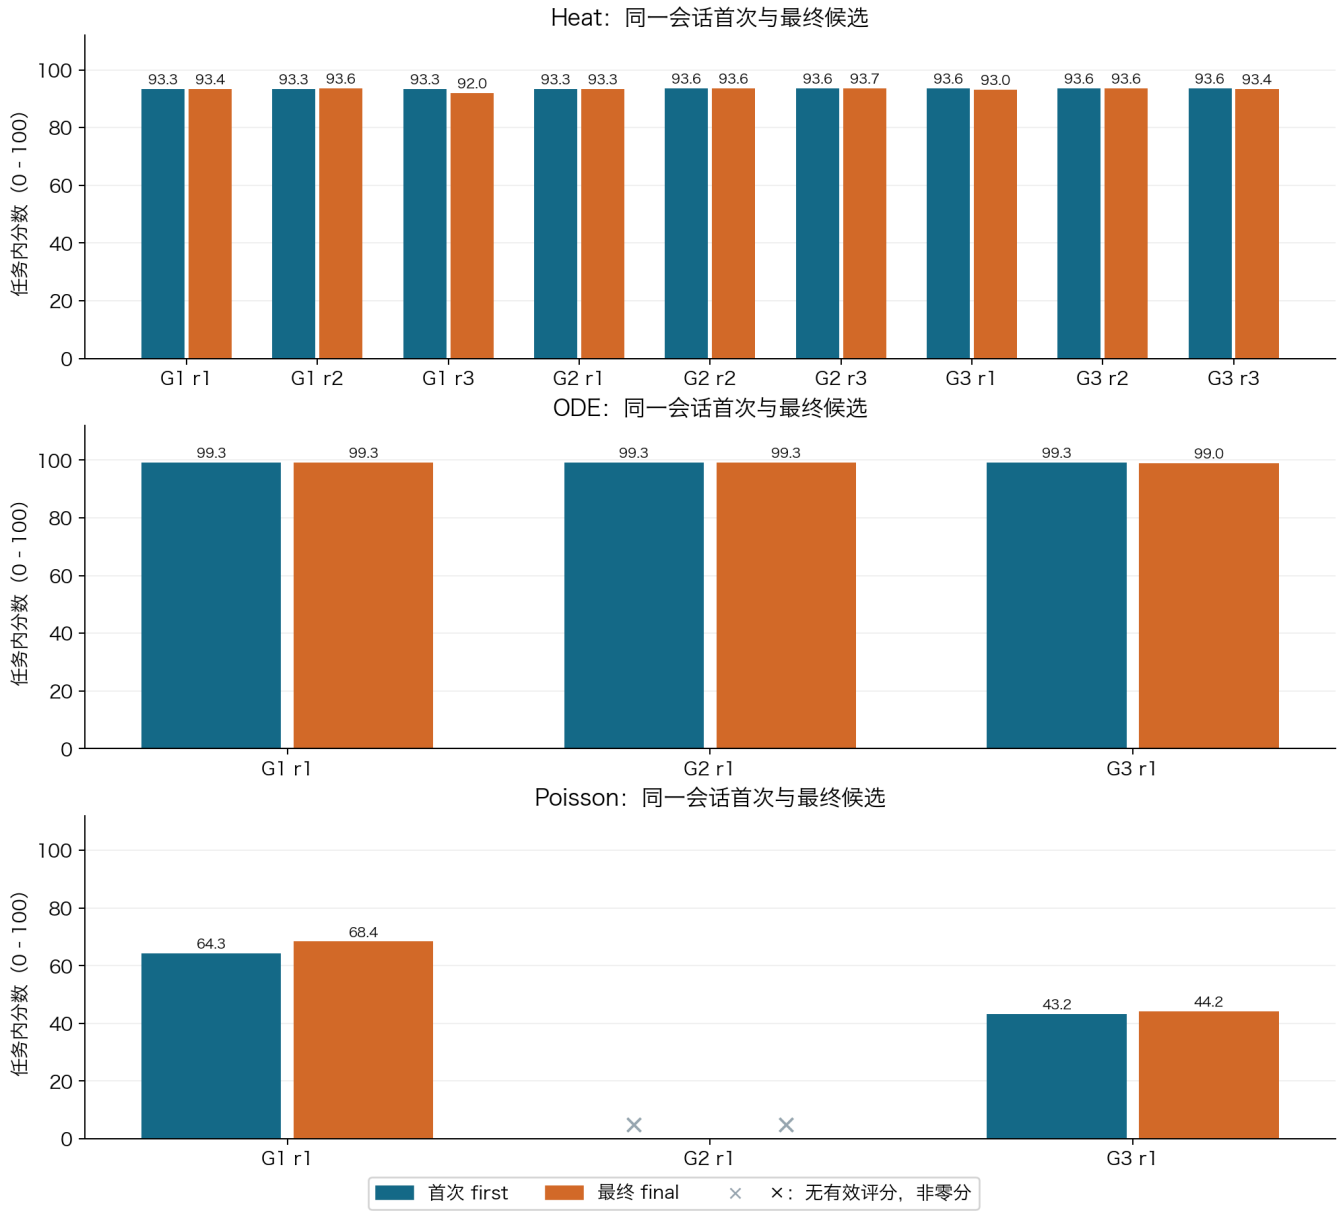


图 2。 两根柱分别为同一研究会话的首次候选与最终候选，不是两批实验。图从零刻度起，不放大微小差异；叉号表示缺少有效分数，位置仅用于标记。柱上值保留一位小数，完整精度在 JSON 中。Poisson G1 的 first 和 final 均来自其获准补测，G2 不画估计分数。

下表与成绩表顺序相同；最后一列是冻结计划中的实际执行序号，便于核对时间线。

序号	会话	first 分	final 分	公开评估次数	输出 token	研究用时（分钟）	实际计划序号
01	Heat G1 r1	93.271	93.388	3	74,089	30.04	3
02	Heat G1 r2	93.271	93.627	2	41,650	5.16	11
03	Heat G1 r3	93.271	91.957	4	50,041	6.09	14
04	Heat G2 r1	93.328	93.328	1	92,474	10.79	1
05	Heat G2 r2	93.637	93.637	1	45,855	5.57	12
06	Heat G2 r3	93.627	93.688	2	43,887	6.17	15
07	Heat G3 r1	93.625	93.041	2	57,574	9.30	2
08	Heat G3 r2	93.625	93.625	1	62,324	11.82	10
09	Heat G3 r3	93.625	93.424	3	65,281	10.36	13
10	ODE G1 r1	99.266	99.266	1	85,921	30.03	4
11	ODE G2 r1	99.266	99.266	1	30,937	23.64	5
12	ODE G3 r1	99.266	98.994	3	63,839	27.74	6
13	Poisson G1 r1	64.342	68.376	3	57,022	10.82	9
14	Poisson G2 r1	—	—	2	75,260	11.10	8
15	Poisson G3 r1	43.204	44.169	3	50,056	16.16	7

公开评估次数不等于全部终端试验次数。输出 token 包括 thinking、普通输出及原生压缩；研究用时取自日志墙钟，超时会话在截止后的关闭检查使读数略超过 30 分钟，不代表提高预算。

first → final 共 **5 升、4 降、5 个源码相同、1 项不可比较**。例如 Heat G1 r3 从 93.271 降至 91.957，ODE G3 r1 从约 99.266 降至 98.994。继续修改并不保证提高隐藏表现。相同源码显式复用评分，不把 first 和 final 算成两个独立研究样本。

用量口径	本轮记录
15 个保留 attempt 的已知输出 token	896,210
加上两个旧失败 attempt 的已知输出 token	925,815
全部 attempt 的 relay charged 输出额度	929,911
保留研究墙钟合计	约 3.580 小时
保留会话公开评估次数合计	32

charged 是代理扣减的额度，包括对不完整失败请求的保守计数，不是供应商货币账单。共 17 个 attempt 对应 15 个研究会话，两个关联重试不增加科学样本；准备、清理、评分和宿主等待也不包含在上表的研究墙钟中。HTTP 成功次数不能等同于有效研究进展，尤其是第 9 节所列无进展续接。

7.4 Poisson G2：保留实测值，明确诊断资格

G2 有合法候选，并在两轮测量中均完成三次候选批次；每次都通过相同的 **12/12 个隐藏实例**。最近一轮最大相对残差约 2.29×10^{-16}，最大相对解误差约 8.24×10^{-13}。这些是保存的数值检查结果；同一实例重复运行不能增加独立样本数。

测量	基线中位耗时（秒）	G2 中位耗时（秒）	原始耗时比（仅诊断）	正式分数
首次测量	1.141403	0.452240	2.524×	未取得有效计时，留空
独立补测	1.095766	0.440336	2.488×	未取得有效计时，留空

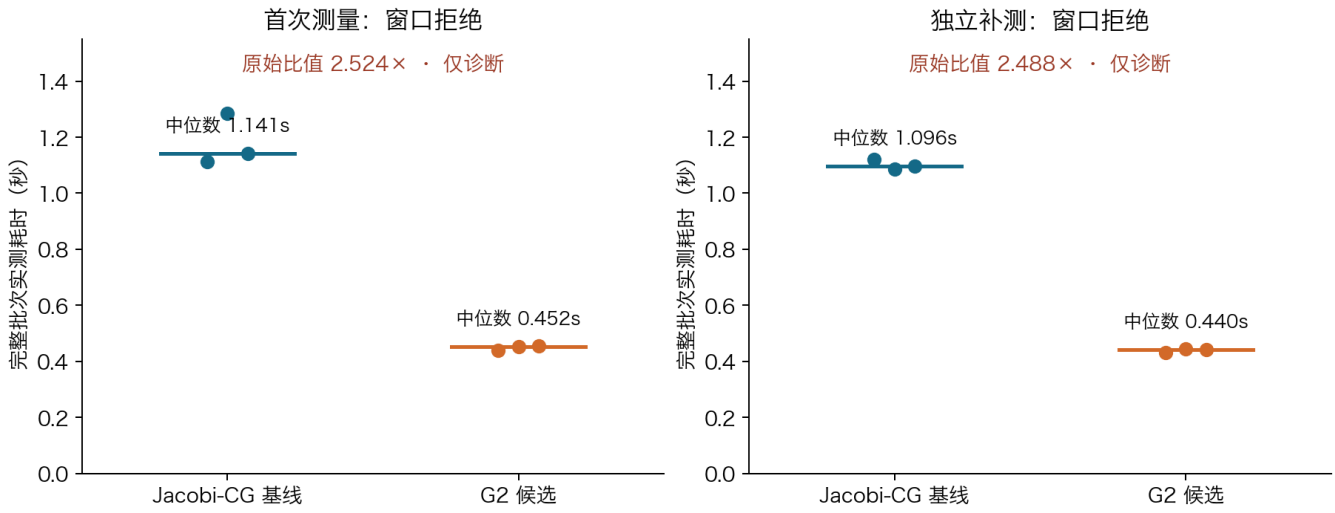


图 3。 每个点代表一次完整批次耗时，短横线为三次中位数。两个窗口都被拒绝，因此图中的原始比值不是正式加速比，不换算成正式分数，也不计入成功数。

最近一次拒绝来自一个约 2.028 秒的区间：VPN 进程增加约 0.11 秒 CPU，用量折算为 5.423%，略高于冻结的 5% 单核阈值。没有新增 swap-out；记录的 swap-in 仅作诊断。首次窗口则同时出现其他进程活跃和 swap-out。两轮比值接近，支持“候选有加速迹象”的诊断描述，但不能证明环境干扰没有影响。

本报告采用最近补测的 **实测 2.488×** 作为明确标注的诊断数值，不估填分数。完整记录见计时报告、补测结果与宿主观察。正式性能仍待合格环境中的新测量；本次报告整理没有启动新的 Agent 或测量。

8. 端到端案例：Heat G1 r2 的可核验改进

该案例属于本轮 thinking/max。Agent 根据详细方法指导实现初场恢复，公开评估两次，宿主登记 `candidate-001` 与 `candidate-002`；原生 Pi 返回后关闭研究。全批研究关闭后，独立评分对两个不同源码候选各重放三次。

项目	首次候选 candidate-001	最终候选 candidate-002
方法	固定尺度的二阶平滑 Tikhonov	按每个实例观测选择平滑先验尺度
参数选择	`alpha=1e-5`，再按最大奇异值定标	在 0.2–8 的 160 点 tau 网格上最大化边际似然
隐藏分数	93.271450	93.626867
正确实例 / reward	12 / 12；1	12 / 12；1
独立重放	3 次	3 次

两种方法都在同一正弦基与二阶平滑结构上求解。最终版根据已知噪声和输入观测选择尺度，替代固定强度；代码没有读取隐藏真值。独立评分改善约 0.355 分，属于小幅改进，不能写成从失败到成功。

公开反馈也可核对：同一个公开实例 `04f4c0643b4ee1f2cbb1` 的残差比 R 从 2.134808 降至 0.890625，粗糙度从 42.301827 升至 53.029407。此例更贴合观测但更不平滑，说明公开代理指标之间有权衡，不能用一个公开数字替代隐藏评分。这里的解释来自候选源码与日志，不补写 Agent 未记录的假设。

可信登记 `state.json` 的实际字段节选如下：


```
{"attempt_status":"completed","closed":true,"first_id":"candidate-
001","final_id":"candidate-002","selection_reason":"explicit_finalize"}
```


独立评分 `diagnostics` 中的字段节选如下（省略逐例结果，不修改数值）：


```
{
  "first": {"checkpoint_id":"candidate-
001","replay_count":3,"score":93.27145000372222,"reward":1},
  "final": {"checkpoint_id":"candidate-
002","replay_count":3,"score":93.62686679721844,"reward":1}
}
```


来源：原始登记及公开反馈、首次源码、最终源码、独立评分 JSON。这也对应第 7 节第 02 行及图 2 的 Heat G1 r2。

9. 结果分析：是否符合预期，原因是什么

9.1 对设计设想的逐项检查

设计设想或合理预期	实际观察	判断与可能原因
三条任务应可运行、独立核验，并存在成功的方法	90 例 QC 通过；本轮 10 项有效作者基线覆盖三任务；三任务均有 Agent 成功案例	达到工程目标；Jacobi 独立窗口拒绝是保留的局限
正则化、去噪和结构约束比简单拟合更稳健	Heat LS 与 ODE 原始差分未通过，强基线通过	符合机制预期：逆问题及数值微分会放大噪声
正确性通过不保证计算效率达标	Poisson CG 正确 12/12，却只有 0.201×；LU 为 2.239×	符合预期：求解策略与四个 RHS 的计算复用影响效率
更多方法指导可能提高稳定性	Heat 各组中位数接近；未呈现可靠的 G1>G2>G3 排序	证据不足；样本少，中途执行器版本也不同
研究迭代可能提高隐藏表现	5 升、4 降、5 源码相同、1 不可比较	部分符合；公开反馈只是代理指标，继续修改也可能破坏有效方案
同一机器的性能测量应可复核	G1 在新窗口通过；G2 两轮窗口被拒绝	宿主噪声是实际限制，数值解正确不等于取得合格速度证据

9.2 基础设施失败及恢复开销

以下三类问题都发生在 thinking 批次，不能混写成模型数学能力不足。失败 attempt、源码版本、修复附录、测试和关联关系均保留。

问题	影响与处理	统计方式
relay 将输入 usage 下调误判为错误	Heat G3 r1 a001 失败；修复后关联 a002 重试	保留 25,070 已知输出与 infrastructure_failed；两个 attempt 仍属一个会话
Pi 在纯 thinking 达到 4,096 上限后未续接	Heat G1 r1 a001 仅 4,535 输出便结束、无提交；修复后关联 a002	保留原 completed 标签，注明协议缺陷，不解释为 Agent 主动完成
续接未进入原生上下文压缩路径	Heat G1 r1 a002 有 252 次单 token 无进展响应，按原 30 分钟关闭并保留候选	保留 research_timeout、74,089 输出及 3 次公开评估；未重跑已有候选

随后修复上下文衔接并继续未开始会话。最终版本留下 378 项完整测试、11 个原生循环和 4 个完整 AgentSession 用例通过的记录；这些是基础设施验证，不是科学样本。单请求 4,096、会话 20 万及科学参数均未变，但执行行为不同，分析组间表现时必须披露。修复链分别见 relay 附录、thinking 续接附录、上下文衔接附录。

9.3 结论的适用范围

本实验支持：三任务和基线可运行，候选可独立核验，本轮 15 个研究会话均形成提交，14 个取得正式成功，迭代既可能改善也可能退化，数值错误与协议、计时问题需要分别解释。

本实验不能证明：开启 thinking 优于关闭 thinking、某指导组普遍更强、一个模型代表所有 Research Agent，或者系统具有原创发现及 RSI 能力。本版没有把非 thinking 数据列为对照；每个任务只有 1 或 3 次组内重复，未进行有充分统计功效的显著性检验。同一隐藏集已使用过、模型路由内部修订不可锁定、中途修复和串行顺序也限制外推。

10. 后续改进方向

优先方向	可实施改进	希望解决的问题与验证方式
提交接口	在新版本明确相对目录、入口和错误原因，增加小型提交演练	减少 empty tar 等非科学失败；在新冻结版本比较提交率
对照公平性	固定修复后的执行器，随机化运行顺序；分别控制 thinking 与 effort	降低基础设施和时间顺序混杂；使用新计划及新隐藏集
样本规模	ODE/Poisson 也增加组内重复，并引入更多模型和数据种子	估计方差，再开展有意义的组间统计比较
任务难度	扩大系数族、观测方式和迁移范围，检验强方法是否接近饱和	避免对当前合成分布过度适配；分层报告难度
性能测量	使用安静的专用宿主，提前确定观察与重测政策	减少 G2 类计时拒绝；完整保留每个窗口，不择优报告
研究过程	记录实验假设、修改与反馈的对应关系，分离重复调用和有效试验	更精确地分析一次改进来自哪里，避免用 HTTP 成功数代替研究进展
RSI 扩展	将 Agent 策略或工具代码作为改进对象，用未参与优化的新任务验收	从“优化当前求解器”扩展到可迁移的自改进；需要单独的安全和评价设计

这些改进属于后续新版本，不会追溯修改本次冻结参数、旧失败或隐藏分数。

11. 作业要求检查与复现交付

作业要求	本版覆盖情况	入口
调研 Auto Research、AI Scientist、Research Agent、RSI 及 Benchmark	六项相关工作，比较任务、环境、工具、指标和局限	第 1–2 节、完整调研
从五个方向选一个	科学计算	第 1、3 节
至少三条完整任务，数据、环境、基线	三任务、90 例 QC、统一输入输出；本轮 10 项有效基线覆盖三任务，1 项拒绝明示	第 3、5、6 节、任务卡
自动评分和隐藏隔离	正确性、研究效果、效率、可复现性；R/W/J 分离与全局研究关闭屏障	第 5 节、隔离协议
至少一条 Agent 端到端验证	三任务均有成功案例；Heat G1 r2 展示真实候选、公开反馈和独立评分	第 7–8 节、15 行证据索引
全部任务基线检查、难度与可靠性分析	强弱基线、三档难度构造、迭代退化、修复与计时拒绝	第 3、6、9–10 节
GitHub 完整交付	调研、任务、数据、配置、基线、判题、原始日志、结果和 README	仓库、Release

无需模型或 Docker 即可核验现有证据并重建排序表：

```
git clone https://github.com/bxf1/sciresearch-bench-lite.git
cd sciresearch-bench-lite
python3 tools/verify_delivery.py
python3 tools/audit_thinking_report.py
python3 tools/build_final_report.py
```

排序表与机器可读数据及 SHA256仅从保存的证据生成；三张图使用同一数据。审计脚本额外核对原始逐例评分、登记与用量，防止表格和图表仅彼此一致却同时写错。制图、HTML/PDF 及实际数值复现的依赖和命令见复现指南。重放已有候选无需模型 API；新 Agent 研究才需要供应商凭据和新冻结计划。

`research-runs/` 与 `logs/` 保留原始记录，完整轨迹与作者数据由 Release 独立附件提供。历史标签的自动源码 ZIP 不是最新 main；请以 main 的本报告和 README 为入口。上一版阅读材料已按文件哈希独立暂存，本次未改写历史证据、失败状态或冻结参数。

12. 结论

本项目完成小规模科学计算 Auto Research Benchmark：三条任务、90 个合成实例、11 种作者方法、隔离环境与自动评分，以及本版展示的 15 个 thinking/max 研究会话。三任务均有有效基线与端到端 Agent 验证，满足作业核心要求；Jacobi 独立基线计时拒绝和 G2 正式性能缺失仍明确保留。

研究结果显示，候选迭代有改进也有退化，正确数值解不必然满足速度要求。15 个会话均有提交，14 项正式成功；G2 的 12/12 数值检查及 2.488× 原始耗时比可作诊断，不能填成正式成绩。完整报告应同时说明结果、来源、失败、开销和限制，而不仅是一张分数表。